

一种多尺度特征融合运动想象脑电信号分类算法 ——基于时频域数据增强

郑敏敏，钱政康，赵桐

(莆田学院 机电与信息工程学院,福建 莆田 351131)

摘要:针对传统的脑电识别算法样本量较小、识别分类准确率较低的问题,提出了一种基于时频域数据增强的多尺度特征融合运动想象脑电信号分类算法。对原始信号进行独立主成分分析滤除眼电噪声,并进行时域和频域的数据增强,将原始数据、时域增强数据、频域增强数据三组数据分别进行多尺度多频带的共空间模式、功率谱密度以及小波包能量特征提取,合并特征并通过特征选择得到最佳特征组,训练支持向量机,由投票得出最终分类结果。在公开数据集BCI Competition IV-2a和OpenBMI上进行验证,结果表明提出的方法分类效果良好,分类准确率高于其他对比方法。

关键词:运动想象;数据增强;共空间模式;支持向量机

A Classification Algorithm for Multi-scale Feature Fusion Motor Imagery EEG Signals

—Based on Time-frequency Domain Data Augmentation

ZHENG Minmin, QIAN Zhengkang, ZHAO Tong

(School of Mechanical, Electrical and Information Engineering, Putian University, Putian Fujian 351131, China)

Abstract: Aiming at the small sample size and low classification accuracy of traditional EEG recognition algorithms, a motor imagery EEG classification algorithm based on multi-scale feature fusion and time-frequency domain data augmentation is proposed. Independent component analysis (ICA) is used to remove ocular artifacts from raw signals, followed by data augmentation in the time and frequency domains. Three types of data—original, time-augmented, and frequency-augmented undergo multi-scale, multi-frequency-band feature extraction, including common spatial pattern (CSP), power spectral density (PSD), and wavelet packet energy (WPE) features. The extracted features are merged and the optimal feature set is selected through feature selection. Then, a support vector machine (SVM) classifier is trained and the final classification result is determined by a voting mechanism. Experiments on the BCI Competition IV-2a and OpenBMI datasets show that the proposed method achieves higher classification accuracy than other comparative methods.

Key words: motor imagery (MI); data augmentation; common spatial pattern; support vector machine

收稿日期: 2024-11-16

基金项目: 福建省科技厅面上项目(2021J011108);莆田学院科研启动项目(2023058);莆田学院研究生科研创新项目(科技类)(yjs2024057)

作者简介: 郑敏敏(1988—),女,福建莆田人,副教授,博士,主要从事脑机接口、生物信号处理等相关领域研究。

0 引言

据中国残疾人联合会统计, 截至 2023 年底, 我国持证残疾人数量为 3 779 万人, 其中肢体残疾人口有 1 130 万人, 占持证残疾人总数的 29.9%^[1]。肢体残疾人中大部分是行动能力受限的运动障碍患者^[2-3]。面对数量庞大的运动障碍患者重获行动能力的需求, 脑机接口(brain-computer interface, BCI)是潜在的解决方案。BCI 系统是链接人脑与外部设备的通道, 能够在不依赖外周神经或肌肉的条件下, 将使用者的思维转化为动作^[4]。运动想象(motor imagery, MI)是 BCI 范式的一种, 是指使用者通过主动想象肢体运动, 激活大脑对应脑区产生脑电信号; 不同的 MI 可以产生不同的脑电信号, 借此可以实现 MI 与外部设备的链接^[5]。脑电信号中包含着丰富的时域和频域信息, 然而由于脑电信号具有非线性、非平稳性、时变性等特点, 常用的短时傅里叶变换、小波变换等时频分析方法^[6], 并不能充分利用脑电信号的时频信息, 因此本文提出了一种基于时频域数据增强的多尺度特征融合 MI 脑电

信号分类算法(time-frequency domain data augmentation-based multiscale feature fusion algorithm, TFDA-MFFA), 用于 MI 脑电信号识别。

1 研究方法

TFDA-MFFA 结构如图 1 所示。该算法分为预处理、特征提取、分类三个部分。预处理部分采用独立主成分分析(independent component analysis, ICA)滤除眼电等伪迹, 并通过时域和频域两种数据增强方法, 得到两组增强后的数据。特征提取部分采用多尺度多频带的方式分别由共空间模式(common spatial pattern, CSP), 以及改进的滤波器组共空间模式(filter bank common spatial pattern, FBCSP)提取空域特征、功率谱密度(power spectral density, PSD)提取频域特征、小波包分解(wavelet packet decomposition)提取时频域特征。将三部分特征进行特征合并, 并由互信息方法进行特征选择, 得到最终特征组合。分类部分采用支持向量机(support vector machine, SVM)作为分类器进行分类, 训练三类 SVM, 并通过投票得到最终分类结果。

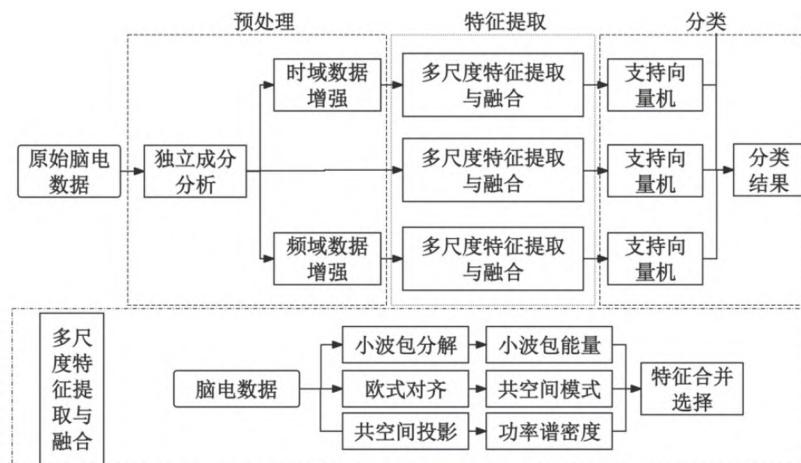


图 1 TFDA-MFFA 结构图

1.1 数据预处理

1.1.1 数据清洗

ICA 是一种常用的脑电信号预处理方法, 能够有效去除脑电信号中的眼电、肌电、心电等伪迹, 提高脑电信号的可靠性和质量^[7]。通过 ICA 将原始脑电信号分解为若干主成分组件, 找到肌电信号与眼电信号等主成分并去除。

1.1.2 数据增强

受样本数量较少影响, 脑电信号识别分类准确率通常偏低。数据分割和重叠是增加数据量的常用方法, 能够提高分类准确率。可以对原始脑电信号进行分割, 来增加脑电信号数据集的样本数量。本文采用的 TFDA-MFFA 方法是: 将脑电信号的第一秒或最后一秒切除掉, 得到两组数

据, 将这两组数据合并, 数据量就扩充为原来的两倍, 完成时域数据增强, 如图2所示。

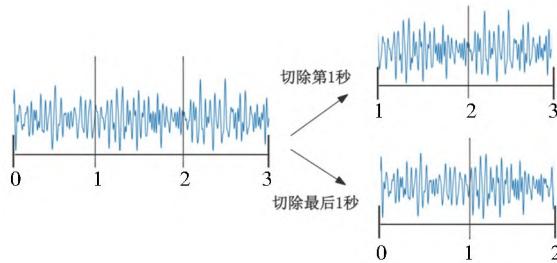


图2 脑电信号时域数据增强示意图

脑电信号在时域和频域上都有比较明显的特点

征, 可在频域上进行数据增强。脑电信号中与MI关系最密切的脑电节律为 α 节律(8~13 Hz)和 β 节律(14~30 Hz)。本文所提TFDA-MFFA算法采用的是基于小波包分解重构的频域数据增强, 步骤如图3所示。具体来说, 对时域数据增强时切除不同时间段得到的两组数据, 分别进行基于db4小波的5阶分解得到32个节点数据(图3仅展示部分5阶分解的各节点效果), 采样率为250 Hz, α 节律大概在第2个节点, 更换两组数据的 α 节律, 再通过小波包重构就得到了两组新的数据, 合并两组数据, 完成频域数据增强。

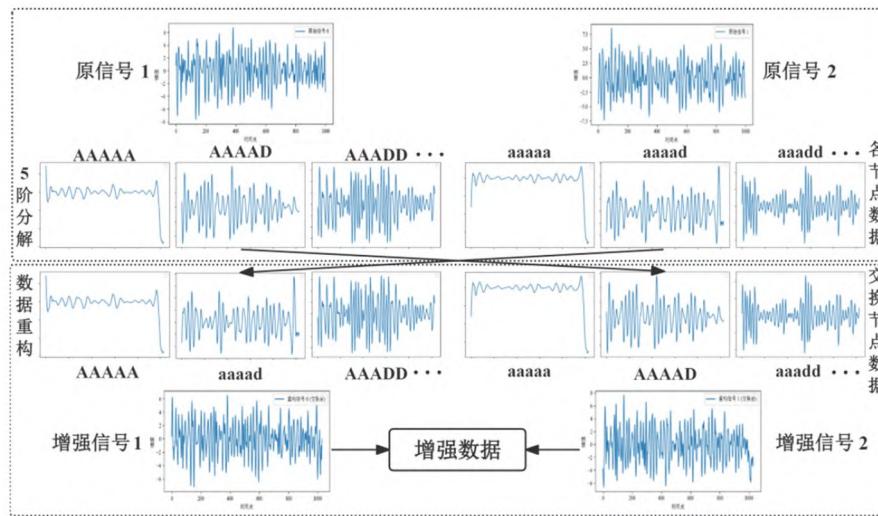


图3 脑电信号频域数据增强示意图

1.2 特征提取与选择

1.2.1 改进FBCSP特征提取

由于脑电信号的非平稳性, 相同受试者的不同会话数据, 存在着分布差异, 可先对经过数据增强的脑电信号进行欧式对齐, 使训练数据与测试数据都偏向同一分布, 从而减小不同会话数据间的分布差异^[8]。设脑电信号训练数据集 X 有 n 个样本, 计算各样本 a 的协方差矩阵的均值。对各样本数据 X_a , 乘以该数据经过白化处理后的白化矩阵, 得到欧式对齐后的脑电像信号数据集 \widetilde{X}_a , 此时各样本脑电信号的分布会更接近。

$$\widetilde{X}_a = \left(\frac{1}{n} \sum_{a=1}^n X_a X_a^T \right)^{-\frac{1}{2}} X_a \quad (1)$$

CSP通过构建投影矩阵, 将原始脑电信号投影到新的空间域上, 通过最大化方差, 最大化两类数据的差异, 提高数据的区分度^[9]。二分类

的CSP算法计算过程如下。

将数据按类别 i 分成不同的数据组 E_i , 计算各类别的协方差矩阵 C_i , tr为求迹符号。

$$C_i = \frac{E_i \cdot E_i^T}{\text{tr}(E_i \cdot E_i^T)}, \quad i = 1, 2, \dots \quad (2)$$

各类别的协方差矩阵 C_i 求均值, 再相加得到总的协方差矩阵 C_c , 对 C_c 进行特征分解, 得到特征向量矩阵 U_c 和特征值 Λ_c , 对 U_c 进行白化处理得到矩阵 P 。

$$P = \frac{1}{\sqrt{\Lambda_c}} \cdot U_c^T \quad (3)$$

将白化矩阵 P 与各类别的协方差矩阵相乘, 进行特征分解得到两组特征值 Λ_1 、 Λ_2 和特征向量矩阵 B , 通过 P 与 B 可以计算得到投影矩阵 W 。

$$W = B^T P \quad (4)$$

利用投影矩阵, 对原始数据进行投影, 得

到特征矩阵 Z , 式(5)中 M 与 N 为矩阵形状示例数。

$$Z_{M \times N} = W_{M \times M} E_{M \times N} \quad (5)$$

特征矩阵的特征并不等效, 经过 CSP 处理得到的特征矩阵, 特征信息更明显集中在特征的首尾, 选择首尾的前几行作为特征输出。

在原本的 FBCSP 中设置 4~40 Hz 步长为 4 进行子带滤波, 得到 9 个子频带。这样的频带划分, 并不能够充分提取频域特征, 本文采用了多尺度的频带划分, 围绕脑电信号中 α 节律和 β 节律, 分别进行了 6、5、4、3、2、1 子带的带通滤波, 具体选择是: 8~32 Hz 步长为 4 的 6 子带, 6~30 Hz 步长为 4 的 6 子带, 8~33 Hz 步长

为 5 的 5 子带, 6~31 步长为 5 的 5 子带, 8~32 Hz 步长为 6 的 4 子带, 6~30 Hz 步长为 6 的 4 子带, 6~30 Hz 步长为 8 的 3 子带, 10~34 Hz 步长为 8 的 3 子带, 8~28 Hz 步长为 10 的 2 子带, 12~32 Hz 步长为 10 的 2 子带, 8~30 Hz 单子带。

笔者认为频带更宽的子带包含的特征信息会更多, 在进行特征提取时, 经过空域滤波得到的时域特征也应该更多。所以在对各子带数据进行 CSP 特征提取时, 对 5、6 子带的数据选择 8 个特征, 3、4 子带的数据选择 12 个特征, 1、2 子带的数据选择 24 特征。将得到的各子带特征进行合并得到多尺度的空域特征。空域特征提取算法流程图如图 4 所示(s 为步长)。

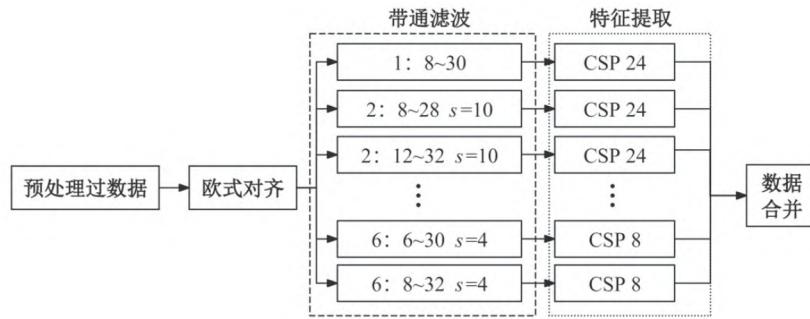


图 4 空域特征提取算法流程图

1.2.2 PSD 特征提取

脑电信号是多通道数据, 不同的通道对应不同脑电极, MI 任务有对应的脑电极, 即输入的脑电信号针对 MI 任务通常存在冗余的。CSP 可以通过构造投影矩阵, 从多通道数据中滤除冗余信号。

本文所提的 TFDA-MFFA 算法对输入的脑电信号先由 CSP 计算投影矩阵, 对脑电信号进行投影。

$$\bar{X}_{A \times E \times D} = X_{A \times C \times D} W_{C \times E} \quad (6)$$

式(6)中, W 为投影矩阵, X 为输入脑电信号, \bar{X} 为投影后的信号, A 、 C 、 D 和 E 为矩阵形状示例数, 无具体含义。

脑电信号是一种非平稳随机信号, 本文采用 PSD 计算脑电信号在不同频率下的功率分布^[10]。设脑电信号长度为 N , 将信号划分为多个有重叠的窗口段, 窗口段数量为 M , 窗口宽度为 L , 窗口段之间重叠长度为 O 。

对每个信号段 $x_b(t)$ 应用汉明窗函数 $\omega(t)$, 得到加窗后的信号段 $\dot{x}_b(t)$ 。

$$\dot{x}_b(t) = x_b(t) \cdot \omega(t) \quad (7)$$

对每个加窗后的信号段 $\dot{x}_b(t)$ 进行快速傅里叶变换, 计算其功率谱, 将 M 个窗口段的功率谱进行平均, 以减少估计的方差, 并除以频率间隔得到 PSD, 可以通过式(8)计算。

$$P_{SD} = \frac{1}{M} \sum_{b=1}^M \left(\frac{1}{N_F} |(\dot{x}_b(t))|^2 \right) \times \frac{1}{\Delta f} \quad (8)$$

式(8)中 P_{SD} 为功率谱密度、 f 为频率间隔, F 为傅里叶变换符号, N_F 为傅里叶变换后对应的信号长度。

本文采用多尺度的方式来进行 PSD 特征提取, 即对脑电信号计算不同窗口宽度的 PSD, 这样处理能够得到不同分辨率下的脑电信号 PSD, 增加了脑电信号频域特征的数量, 提高了分类器的泛化能力, 使其能够更好地适应不同的信号类型和噪声环境。具体来说, 本文分别计算窗口宽

度为 256、512、768 时间点的脑电信号 PSD，采用 CSP 来最大化各类间的差异，提取特征。

本文认为不同窗口宽度下的脑电信号 PSD 具有不同的分辨率，窗口越宽，分辨率越高，应该提高这一部分 PSD 的权重，可以通过 CSP 提取不同数量的特征来进行。对于窗口宽度为 256、512、768 时间点的 PSD，分别选择 16、24、32 个特征。频域特征提取算法流程图如图 5 所示。

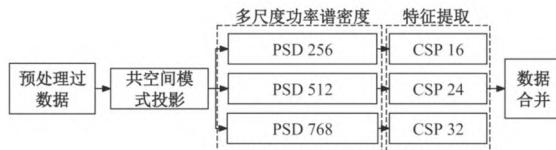


图 5 频域特征提取算法流程图

1.2.3 小波包能量特征提取

小波包分解能够对数据进行多层次的频带划分，可以在不同时间和频率尺度上分析脑电信号，在高频部分也能够获得足够的分辨率。本文所提 TFDA-MFFA 算法对经过数据增强的脑电信号进行小波包分解，原始脑电信号 $x(t)$ 经小波包分解至第 j 层，可以得到 2^j 个子频带。 $x(t)$ 的表达式为：

$$x(t) = \sum_{k=0}^{2^j-1} f_{j,k}(t_j) = f_{j,0}(t_0) + \cdots + f_{j,2^{j-1}}(t_{2^{j-1}}) \\ k = 0, 1, \dots, 2^j - 1 \quad (9)$$

式(9)中， $f_{j,k}(t_j)$ 是节点 (j, k) 处的重构信号， j 为小波包分解层数， k 为节点在第 j 层上的位置。

选用 db4 小波对脑电信号进行 5 阶小波包分解，各节点处的能量特征可以通过式(10)计算得到。

$$E(j, k) = \frac{1}{m} \sum_{l=1}^m [d_l(j, k)]^2, \\ l = 1, 2, \dots, m \quad (10)$$

式(10)中， $E(j, k)$ 为节点 (j, k) 的小波包能量 (wavelet packet energy, WPE)， $d_l(j, k)$ 为第 j 层第 k 个位置的小波包系数， l 为节点编号， m 为第 j 层小波包系数个数。

本文通过计算多尺度的 WPE 来进行脑电信号的时频域特征提取，通过不同阶数的小波包分解，能够得到更多的节点，可以对脑电信号进行

不同颗粒度的分析。更多的节点也意味着可以从信号中提取更多的特征信息，从而可能提高算法的性能。具体来说，本文采用基于 db4 小波的 3、4、5 阶小波包分解，分别得到 8、16、32 个节点的数据，并计算各节点的 WPE。本文认为不同尺度的节点能量包含的特征不同，通过 CSP 分别提取 16、12、8 个特征，作为时频域特征。时频域特征提取算法流程图如图 6 所示。

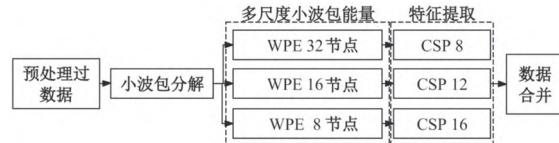


图 6 时频域特征提取算法流程图

1.2.4 特征选择

将改进 FBCSP 提取的特征、PSD 特征以及 WPE 特征合并得到总的特征集合，由于采用多尺度的方式提取特征，可能存在特征冗余的情况，需要进行特征选择来得到最优特征集合。互信息能够衡量特征与目标变量之间的依赖程度，通常用于高维数据的特征选择，互信息值越大，表明特征与目标变量的相关性越强。互信息的定义式如下。

$$I(X; Y) = H(X) + H(Y) - H(X, Y) \quad (11)$$

式(11)中， $I(X; Y)$ 表示随机变量 X 与 Y 的互信息， $H(X)$ 、 $H(Y)$ 分别表示随机变量 X 、 Y 的熵， $H(X, Y)$ 表示随机变量 X 和 Y 的联合熵。

本文通过互信息来进行特征选择，根据各个特征的得分情况，选择得分最高的若干特征作为最终的分类特征。基于互信息法的特征选择流程图如图 7 所示。

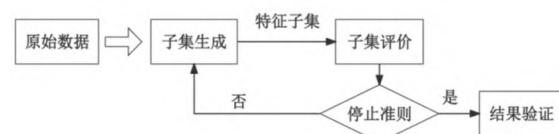


图 7 互信息法特征选择流程图

1.3 识别分类

SVM 是一种用于二分类任务的分类算法，其核心思想是寻找最优超平面来划分两类数据。脑电信号具有非线性和时空复杂度较高的特性，传统分类方法并不适用于脑电信号分类^[11]。本

文采用多分类策略(将多分类问题分解为一系列的二分类问题)的 SVM 作为分类器, 并通过在 SVM 中引入核函数来改善其在非线性数据上的分类效果。SVM 算法判别函数如下:

$$Z_a[(v \cdot x_a) + y] - 1 - \xi_a \geq 0, \\ a = 1, 2, \dots, n \quad (12)$$

式(12)中, Z_a 为第 a 个样本的分类标签, v 为间隔, x_a 为第 a 个数据点, y 为超平面截距, ξ_a 为松弛项, n 为样本总数。可通过拉格朗日乘子法求解最优, 利用二次规划来最小化目标函数, 则有最佳分类超平面函数 $f(x)$ 。

$$f(x) = \text{sgn}\left(\sum_{a=1}^n a^* Z_a K(x_i, x) + y^*\right) \quad (13)$$

式(13)中, sgn 为符号函数, a^* 为超平面法向量, a^* 与 y^* 是通过迭代得到的, $K(x_i, x)$ 为核函数。

本文使用高斯核函数实现信号的非线性映射, 分类部分选择适用于多分类的一对剩余(one vs rest, OVR)决策模式的 SVM 作为分类器。采用原始数据、时域增强后数据、频域增强后数据分别训练 SVM, 并通过投票得到最终的分类结果。

2 实验数据来源

2.1 BCI Competition IV-2a 数据集

实验采用第四届脑机接口大赛所用的 BCI Competition IV-2a 数据集^[12], 采集了 9 名受试者的脑电信号。每位受试者都进行左手(1类)、右手(2类)、双脚(3类)和舌头(4类)四种 MI 任务, 每轮实验进行 48 次测试, 四种想象任务的数量均衡, 共进行 6 轮实验, 即每位受试者共计进行 288 次 MI 任务。每次 MI 任务开始时, 响起提示音, 屏幕由黑转为中央十字亮起, 前 0~2 s, 受试者注视屏幕中的十字保持放松; 接着屏幕上随机出现对应四种想象任务的箭头指令, 指令持续 1.25 s, 受试者按指令执行相应 MI 任务, 持续到屏幕上的十字消失(持续到第 6 秒结束)。实验共进行两次, 得到 session0 和 session1 两个数据子集, 分别作为训练集 T 和测试集 E。图 8 是 BCI Competition IV-2a 数据集单次 MI 任务流程示意图。



图 8 BCI Competition IV-2a 数据集

单次 MI 任务流程示意图

2.2 OpenBMI 数据集

实验采用韩国 OpenBMI 数据集^[13], 采集了 54 名健康受试者的脑电信号, 其中 38 名受试者为初次使用 BCI 设备, 其余均有使用经验。每位受试者都进行左手(1类)、右手(2类)两种 MI 任务, 两种想象任务的数量均衡, 进行 100 次实验。实验共进行两天, 得到两个数据子集。每次实验开始后, 0~3 s 屏幕中央出现十字, 随后屏幕上随机显示左右箭头提示, 受试者按照提示想象对应左手或右手的抓握运动 4 s。每个任务结束, 休息 6 s 左右, 屏幕空白。图 9 为 OpenBMI 数据集单次 MI 任务流程示意图。

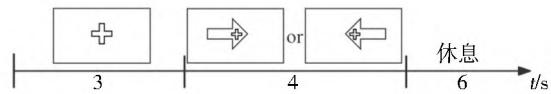


图 9 OpenBMI 数据集单次 MI 任务流程示意图

3 评价标准与结果讨论

3.1 评价标准

为了便于评价本文所提 TFDA-MFFA 算法的性能, 将数据集分为训练集和测试集, 采用训练集对该算法进行训练, 得到相应的模型, 再用测试集测试模型性能, 对各受试者数据分别进行训练, 结果取平均。采用准确率 A 以及 κ 值两个指标来评价模型性能^[14]。两个指标的计算公式如下。

$$A = \frac{T_p + T_n}{T_p + F_n + F_p + T_n} \quad (14)$$

准确率 A 计算的是预测正确的样本占总样本的比例, 其中 T_p 为真正类, T_n 为真反类, F_p 为假正类, F_n 为假反类。 A 的值在 0 到 1 之间, 越接近 1, 模型性能越好。

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \quad p_o = \frac{\sum_{i=1}^c T_i}{n}, \quad p_e = \frac{\sum_{i=1}^c a_i * b_i}{n^2} \quad (15)$$

κ 值是基于混淆矩阵进行计算的，用于比较实际分类与随机分类的差异，以评估模型性能。式(15)中： C 为类别总数， n 为总样本数， T_i 为第 i 类正确分类样本数； p_o 为总体分类精度，是各类别正确分类的样本数之和与总样本数的比值； a_i 为第 i 类样本个数， b_i 为预测出的第 i 类样本个数； p_e 为预期分类精度，是按照样本分布随机分类的预期正确率。 κ 值在 -1 到 1 之间，越接近 1 则表示模型性能越好。

3.2 结果讨论

选择多分类策略的 SVM 作为分类器进行分类，影响分类准确率的因素包括 SVM 核函数的选择和惩罚系数 c 的选择^[15]，下文将对这两个影响因素进行实验探究。首先保证选择的特征数量相同，SVM 的惩罚系数 c 选择默认值 1，对比核函数的选择对分类准确率的影响，对 BCI Competition IV-2a 数据集 9 位受试者的脑电信号进行测试，取平均分类准确率作为衡量标准，实验结果如图 10 所示。对比 SVM 四种核函数(线性核函数 linear、多项式核函数 poly、高斯核函数 rbf 以及 sigmoid 核函数)的分类准确率，发现 rbf 分

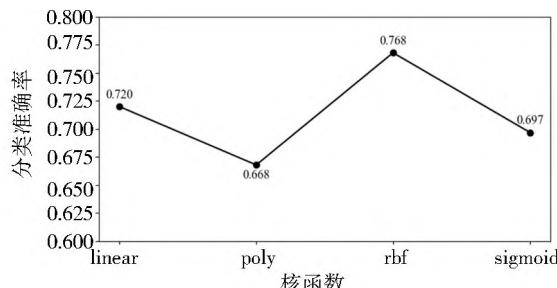


图 10 选择不同核函数的 SVM 的分类准确率

类准确率最高，故选择 rbf 作为 SVM 的核函数。SVM 的惩罚系数 c 是对于误分类点的惩罚程度，惩罚系数 c 的选择对于分类准确率的影响明显。同样，在保证选择的特征数量相同的情况下，核函数选择 rbf，对比惩罚系数 c 的值对分类准确率的影响，对 BCI Competition IV-2a 数据集 9 位受试者的脑电信号进行测试，取平均分类准确率作为衡量标准，实验结果如图 11 所示。从图 11 可知，随着惩罚系数 c 的增加，分类准确率经历了先增后略减接着缓慢增加的变化过程，在 $c=0.9$ 时分类准确率最高，故取 $c=0.9$ 作为 SVM 的惩罚系数。

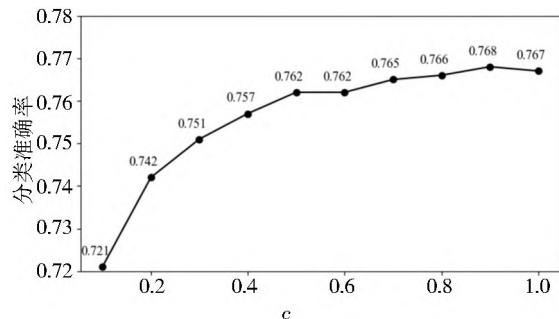


图 11 不同 c 参数值的分类准确率

对 BCI Competition IV-2a 数据集进行 MI 四分类实验。多尺度 PSD 共空间模式方法(MPSDCSP)、多尺度多频带改进滤波器组 CSP 方法(MFBCSP)、本文提出的 TFDA-MFFA 对 BCI Competition IV-2a 数据集上不同受试者脑电信号的分类准确率如图 12 所示。可以看到，TFDA-MFFA 在 9 名受试者的脑电信号上都有更好的分类表现，其中在 1、3、4、7、8、9 号受试者的脑电信号上，该方法

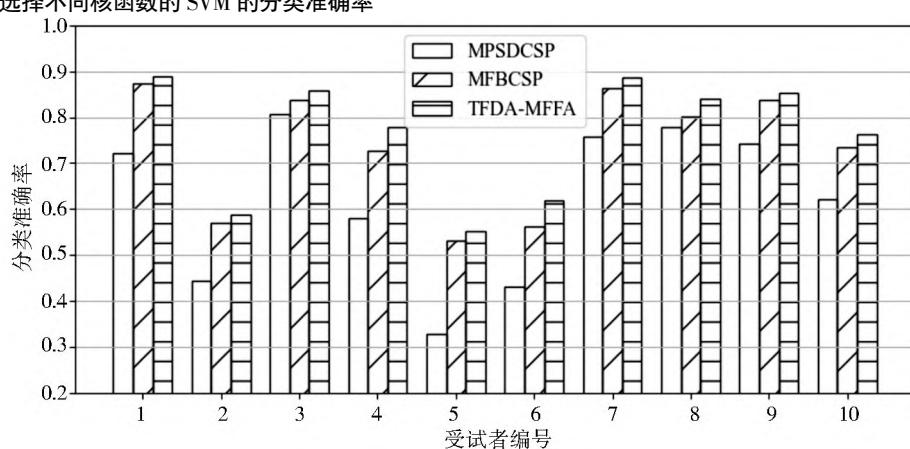


图 12 不同方法对 BCI Competition IV-2a 数据集的分类准确率

分类效果较好, 在1号受试者脑电信号上分类准确率最高, 达到了0.892; 在2、5、6号受试者的脑电信号上, 分类效果较差, 其中对5号受试者脑电信号的分类准确率低至0.563。该方法的平均分类准确率达到了0.768, 相较于MPSDCSP的0.621提高了0.147, 相较于MFBCSP的0.750提高了0.018。

将MPSDCSP与MFBCSP结合得到的本文所提的TFDA-MFFA, 获得了更强的特征表达。以3号受试者的脑电信号为例, 采用 t -SEN(t -SNE)可视化。

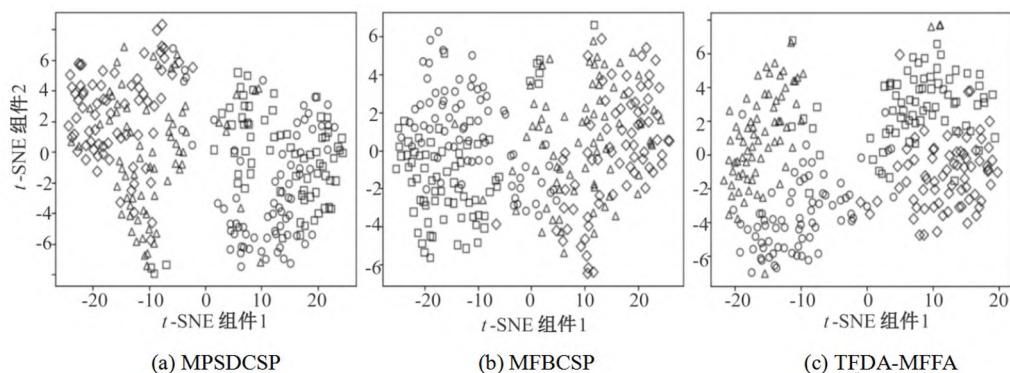


图13 各方法的特征融合后脑电信号 t -SEN可视化对比图

为了验证本算法的可靠性, 对OpenBMI数据集上54名受试者两次不同会话的脑电信号采用相同的处理方式, 实验结果如图14所示。TFDA-MFFA对54名受试者脑电信号的平均分类准确率为0.732, 其中最高的分类准确率达到0.975, 最低的分类准确率仅为0.485, 分类准确率差异较大是由于未接触过脑电采集的受试者的脑电信号噪声较大。

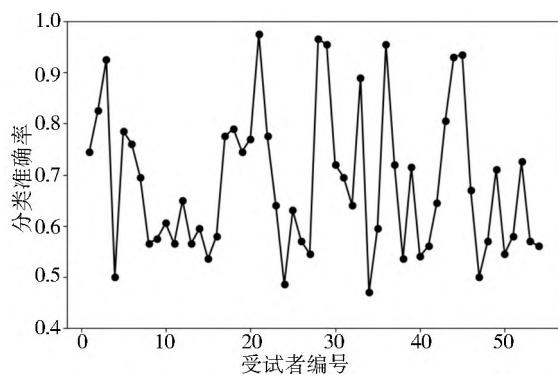


图14 TFDA-MFFA对OpenBMI数据集的分类准确率

针对本文所用的时域与频域数据增强结合的方法, 采用BCI Competition IV-2a数据集进行验

distributed stochastic neighbor embedding)算法将特征融合后的四类脑电信号可视化, 如图13所示, 从左到右依次是MPSDCSP、MFBCSP以及TFDA-MFFA的特征融合后脑电信号可视化图, 各可视化图中, 圆形、三角形、菱形以及方形分别代表四种不同类别的脑电信号。从图13中可以看出, 采用TFDA-MFFA, 经过特征融合后的四个类别的脑电信号呈现出较为明显的区分, 相互之间重叠部分较少, 即四类脑电信号在特征空间中较容易区分, 类别之间在高维特征上存在显著差异。

证, 分别采用原始数据、时域与频域数据增强后数据作为训练数据集, 通过多尺度特征融合MI脑电信号分类算法(MFFA)进行训练, 并对比两种训练结果在BCI Competition IV-2a测试集上的分类表现, 如图15所示。从图15可以看出, 使用经过数据增强后的数据进行训练, 取得了更好的测试效果, 平均分类准确率相较于使用原始数据训练的0.760提升了0.008, 达到0.768。通过对比可以知道, 数据增强方法对于提高分类准

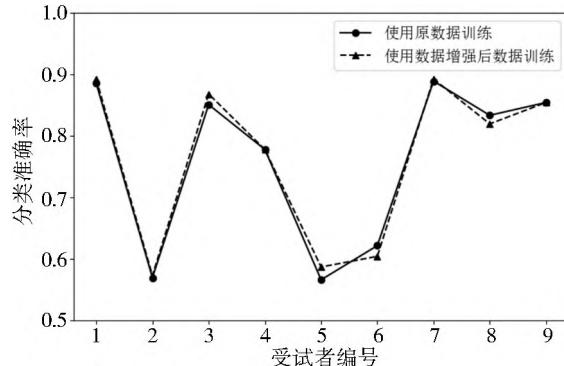


图15 使用TFDA-MFFA在原始数据上训练和数据增强后数据上训练的分类效果对比

确率有帮助，但可能受限于传统算法的特性，分类准确率的提高并不显著。

对比 TFDA-MFFA 与同样使用 BCI Competition IV-2a 数据集进行测试的其他文献所提算法的分类准确率与 κ 值，结果如表 1 所示。从表 1 可以看出，TFDA-MFFA 在 BCI Competition IV-2a 数据集上的分类准确率是最高的，对应的 κ 值也是最高的，即 TFDA-MFFA 在对比算法中的分类效果最好，分类结果也最可靠。

表 1 各方法分类效果对比

数据集	方法	平均分类准确率	κ
BCI Competition IV-2a	FBCSP ^[16]	0.658	0.573
	MDRM ^[17]	0.633	0.541
	ICAW-CSP ^[18]	0.716	0.614
	MTF-CSP ^[19]	0.761	0.677
	TFDA-MFFA	0.768	0.689
OpenBMI	FBCSP	0.678	/
	MDRM	0.649	/
	ICAW-CSP	0.694	/
	MTF-CSP	0.712	/
	TFDA-MFFA	0.732	/

注：表中 OpenBMI 数据集的对比数据，采用对应论文数据，无 κ 值。

将表 1 中的对比数据进行 t 配对分析，结果如表 2 所示。本文设置显著水平比较值为 0.05，即 P 值小于 0.05，则两组数据差异显著。从表 1 中可以看出，除 MTF-CSP 方法外，TFDA-MFFA 与其他方法对比，分类结果差异显著。TFDA-MFFA 的平均分类准确率为 0.768，较 MTF-CSP 方法高 0.007。

表 2 设置 P 值为 0.05 的 t 配对分析

方法	P 值 (<0.05)
FBCSP	0.00015*
MDRM	0.00002*
ICAW-CSP	0.00013*
MTF-CSP	0.23377

注：表中括号内为显著水平比较值，* 代表差异显著。

4 结论

本文提出了一种基于时频域数据增强的多尺度特征融合运动想象脑电信号分类算法 (TFDA-MFFA)：对原始脑电数据进行时域和频域的数

据增强，采用原始数据、时域增强数据、频域增强数据三组数据分别训练 SVM，并由投票得出最终分类结果。将 TFDA-MFFA 在 BCI Competition IV-2a 数据集和 OpenBMI 数据集上进行了验证，并与其他方法进行了对比。结果表明，本文所用的数据增强方法能够得到接近于真实脑电数据的人工数据，对于提高分类准确率有帮助；且提出的 TFDA-MFFA 能够有效提高运动想象多分类任务的分类准确率，为运动想象脑机接口研究提供了新的思路。

参考文献：

- [1] 中华人民共和国统计局. 中国统计年鉴 [M]. 北京：中国统计出版社，2024:22–26.
- [2] 白先春，李筱菁. 残疾调查纳入人口普查的国际经验及对我国的启示 [J]. 残疾人研究，2023(2):65–72.
- [3] 陈盼盼，王炳龙，王虎军，等. 肢体残疾人辅具使用现状及影响因素分析 [J]. 中国康复，2024, 39(7):439–443.
- [4] XIONG T, HU R, SHAO H, et al. Control of upper limb rehabilitation robot based on steady-state visual evoked potential [J]. Science Technology and Engineering, 2021, 21(17):7237–7242.
- [5] KEUTAYEVA A, FAKHRUTDINOV N, ABIBULLAEV B. Compact convolutional transformer for subject-independent motor imagery EEG-based BCIs [J]. Scientific Reports, 2024, 14:1–11.
- [6] 赵伟. 基于 CNN-LSTM 模型的癫痫脑电信号识别方法 [J]. 莆田学院学报，2023, 30(5):69–74.
- [7] 鲍甜恬，欧阳虹霞，杨天宇，等. 基于 ICA-CSP-KNN 的运动想象脑电意图识别 [J]. 科技创新与应用，2023, 13(30):6–9.
- [8] HE H, WU D R. Transfer learning for brain-computer interfaces: a Euclidean space data alignment approach [J]. IEEE Transactions on Biomedical Engineering, 2020, 67(2):399–410.
- [9] 刘帅，乌日开西·艾依提. 基于 VMD 与 CSP 的脑电特征提取方法 [J]. 计算机仿真，2022, 39(11):432–437.
- [10] 赵德春，沈利豪，蒋宇皓，等. 基于共空间模式和功率谱密度的脑电信号分类 [J]. 科学技术与工程，2023, 23(10):4272–4278.

(下转第 70 页)

- (3):178-184.
- [14] LUKASZ M, MAREK W, KRZYSZTOF W, et al. Elements of designing upholstered furniture sandwich frames using finite element method [J]. Materials, 2022, 15(17):6084.
- [15] 张帆. 基于有限元法的实木框架式家具结构力学研究[D]. 北京: 北京林业大学, 2012.
- [16] 杜光耀, 龚京鸿, 刘学革. 基于有限元法的竹集成材新中式椅轻量化设计[J]. 林产工业, 2023, 60(5):39-44.
- [17] 何佳容, 易礼琴, 黄凯, 等. 面向数字化制造的圈椅榫卯结构设计[J]. 林产工业, 2023, 60(5):77-81.
- [18] 李静, 刘豪, 华腾飞, 等. 一种考虑平均应力影响的疲劳寿命预测方法[J]. 华中科技大学学报(自然科学版), 2024, 52(12):70-76.

[责任编辑 杨聪华]

(上接第 60 页)

- [11] MARY J A, BAGHAVATHI P S, MAHENDRAN R K, et al. Two-phase classification: ANN and A-SVM classifiers on motor imagery BCI[J]. Asian Journal of Control, 2022, 25(5):3318-3329.
- [12] 曹铉, 罗天健. 运动想象脑电信号的跨被试动态多域对抗学习方法[J]. 计算机应用, 2024, 44(2):645-653.
- [13] MIN-HO L, O-YEON K, YONG-JEONG K, et al. EEG dataset and OpenBMI toolbox for three BCI paradigms: an investigation into BCI illiteracy [J]. GigaScience, 2019, 8(5):1-16.
- [14] 彭禹, 宋耀莲, 杨俊. 基于数据增强的运动想象脑电信号分类[J]. 计算机应用, 2022, 42(11):3625-3632.
- [15] SHANG Y, GAO X, AN A M. Multi-band spatial feature extraction and classification for motor imaging EEG signals based on OSFBCSP-GAO-SVM model: EEG signal processing [J]. Medical & Biological Engineering & Computing, 2023, 61(6):1581-1602.
- [16] CHIN Z Y, ANG K K, GUAN C. Multiclass voluntary facial expression classification based on filter bank common spatial pattern [C] // 2008 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. Vancouver: IEEE, 2008:1005-1008.
- [17] ALEXANDRE B, STEPHANE B, MARCO C, et al. Multiclass brain-computer interface classification by Riemannian geometry [J]. IEEE Transactions on Biomedical Engineering, 2012, 59(4):920-928.
- [18] GENG X Z, LI D Z, CHEN H L, et al. An improved feature extraction algorithms of EEG signals based on motor imagery brain-computer interface[J]. Alexandria Engineering Journal, 2022, 61(6):4807-4820.
- [19] YANG J, MA Z, SHEN T. Multi-time and multi-band CSP motor imagery EEG feature classification algorithm [J]. Applied Sciences, 2021, 11(21):10294.

[责任编辑 林振梅]