

基金项目论文

# 融合时空卷积和注意力机制的脑电信号分类

曾韵晗<sup>1</sup> 孙洪伟<sup>1</sup> 杨玲<sup>2</sup>

(1. 上海理工大学健康科学与工程学院, 上海 200093; 2. 同济大学附属上海市第四人民医院老年医学科, 上海 200434)

**摘 要:** 脑电信号受多种因素影响, 导致其解码准确率较低。为解决脑电信号识别精度不高的问题, 本文提出了一种融合时空卷积和注意力机制的分类模型。该模型结合了紧凑卷积神经网络 (EEGNet) 在时间和空间特征提取方面的优势, 以及时间卷积网络 (TCN) 在处理时间序列数据上的强大能力。同时, 模型引入了注意力机制和基于卷积的滑动窗口技术, 以增强对关键特征的识别与利用。在 BCI Competition IV-2a 数据集上进行实验, 结果表明, 该模型的平均分类准确率达到 83.9%, 平均 Kappa 值为 0.79, 显著优于现有多种模型。该模型通过有效应对 EEG 信号的非平稳性和个体差异性, 显著提升了运动现象 (MI) 任务的分类性能。

**关键词:** 运动想象; 脑电信号分类; 卷积神经网络; 时间卷积网络; 注意力机制; 滑动窗口

中图分类号: TN911.7

文献标识码: A

DOI: 10.3969/j.issn.1003-6970.2025.01.004

本文著录格式: 曾韵晗, 孙洪伟, 杨玲. 融合时空卷积和注意力机制的脑电信号分类[J]. 软件, 2025, 46(01): 010-016

## EEG Signals Classification by Fusing Spatio-temporal Convolution and Attention Mechanism

ZENG Yunhan<sup>1</sup>, SUN Hongwei<sup>1</sup>, YANG Ling<sup>2</sup>

(1. School of Health Science and Engineering, University of Shanghai for Science and Technology, Shanghai 200093;

2. Department of Geriatrics, Shanghai Fourth People's Hospital Affiliated to Tongji University, Shanghai 200434)

**【Abstract】** : The electroencephalogram (EEG) signal is influenced by multiple factors, leading to a relatively low decoding accuracy rate. To address the issue of the low recognition accuracy of EEG signals, this paper presents a classification model that integrates spatiotemporal convolution and the attention mechanism. This model combines the advantages of the compact convolutional neural network (EEGNet) in extracting temporal and spatial features, as well as the strong capability of the temporal convolutional network (TCN) in processing time series data. Simultaneously, the model incorporates the attention mechanism and the convolution-based sliding window technique to enhance the recognition and utilization of key features. Experiments were conducted on the BCI Competition IV-2a dataset, and the results showed that the average classification accuracy of the model reached 83.9%, with an average Kappa value of 0.79, significantly better than existing models. This model significantly improves the classification performance of the motor imagery (MI) task by effectively coping with the non-stationarity and individual differences of EEG signals.

**【Key words】** : motor imagery; EEG signal classification; convolutional neural network; temporal convolutional networks (TCN); attention mechanism; sliding window

### 0 引言

是一种直接在大脑和外部设备之间建立通信的系统, 通过解读大脑信号, 实现对设备的控制。其中, 脑电图 (Brain-Computer Interface, BCI) 技术

基金项目: 上海市科学技术委员会基金 (24692113500); 上海市虹口区卫生健康委员会临床重点扶持专科—老年医学科 (HKLCFC202412); 上海市虹口区卫生健康委员会医学科研课题重大项目 (虹卫 2301-03); 同济大学附属上海市第四人民医院院基金项目 (sykyqd06401)

作者简介: 曾韵晗 (2001—), 女, 硕士, 研究方向: 脑电信号分类, 深度学习; 孙洪伟 (2000—), 男, 硕士, 研究方向: 脑电信号分类、深度学习。

通讯作者: 杨玲 (1973—), 女, 医学博士, 教授, 研究方向: 老年医学。

(Electroencephalogram, EEG) 是一种非侵入性方法, 通过在头皮上放置电极捕捉大脑的电活动<sup>[1]</sup>。在临床上, EEG 被广泛用于癫痫、睡眠障碍等多种疾病的诊断。与侵入式方法相比, EEG 具有无需手术、风险低、成本相对较低、适用范围广以及时间分辨率高等优势<sup>[2]</sup>, 因此脑电信号被广泛用于脑机接口技术中。

运动想象 (Motor Imagery, MI) 是一种通过思考身体某部位的运动而不实际进行肢体移动的活动。这项技术在运动康复领域展现出巨大潜力, 可用于帮助因中风、脊髓损伤或其他神经肌肉疾病而丧失运动能力的患者<sup>[3]</sup>。通过运动想象, 患者能够在没有实际肢体动作的情况下激活大脑的运动网络, 从而促进神经可塑性和功能恢复。这一机制已被广泛应用于脑控智能轮椅、外骨骼控制等辅助技术中, 为患者提供了更多的康复可能性<sup>[4]</sup>。

在 BCI 系统中, 信号分类是其中的核心任务之一。该过程包括从脑电信号中提取特征, 并利用这些特征来区分不同的大脑活动状态, 例如想象运动、视觉刺激反应或注意力集中等。信号分类的准确性对 BCI 系统的性能至关重要, 因为它直接决定了系统的响应速度和控制精度。然而, 脑电信号容易受到多种因素的影响, 例如噪声干扰、个体差异以及信号采集条件等, 同时大脑活动的动态性也进一步增加了分类的难度。为提高分类准确性, 研究人员探索了多种方法, 包括传统的统计分析、先进的机器学习算法以及深度学习技术。深度学习尤其表现出强大的潜力, 已在图像、视频、音频和文本分析等领域取得显著成功<sup>[5-8]</sup>。受其他领域成果的启发, 许多研究人员开始采用深度学习算法对 MI 任务进行分类, 为 BCI 系统的发展提供了新的突破口。

在过去几年中, 研究人员提出了多种传统机器学习和深度学习方法用于运动想象 (MI) 的分类。传统的机器学习方法通常依赖手动特征提取, 其中滤波器组公共空间模式 (FBCSP)<sup>[9]</sup> 及其多种变体在运动想象脑电信号分类中表现出了优异的性能。相比之下, 神经网络方法则无需对原始 EEG 数据进行复杂的预处理或手动特征提取。例如, Olivas-Padilla 等人<sup>[10]</sup> 结合卷积神经网络 (CNN) 和 CSP 算法, 并通过贝叶斯优化模型, 对包括多类 MI 任务在内的空闲状态进行了分类。实验结果表明, 该方法在不增加计算时间的情况下, 其分类准确率优于许多经典智能识别方法。Vernon J. Lawhern 等人<sup>[11]</sup> 提出了一种紧凑型卷积网络 EEGNet, 用于基于 EEG 的脑机接口 (BCI)。EEGNet 结合了深度卷积和可分离卷积, 能够更好地泛化多种实验范式并实现较高的性能。此外, Yazeed K. Musallam 等人<sup>[12]</sup> 提出了

一种用于 MI-EEG 分类的高效模型 TCNet-Fusion。该模型整合了时间卷积网络 (TCN)、可分离卷积、深度卷积以及层融合技术。实验表明, TCNet-Fusion 在分类性能上优于许多基于固定超参数的 CNN 模型。TM Ingolfsson 等人<sup>[13]</sup> 则开发了一种新颖的 EEG-TCNet 模型, 将 TCNet 与 EEGNet 架构结合, 仅使用少量可训练参数即可实现卓越的分类准确性。

注意力机制是深度学习中的一种关键技术, 模仿了人类在处理信息时选择性关注特定部分的能力。在运动想象脑电分类领域, Jincan Zhang 等人<sup>[14]</sup> 提出 CNN-GRU-AM 模型, 通过引入注意力机制, 模型能够聚焦于关键特征, 从而提升识别能力。Guowen Xiao 等人<sup>[15]</sup> 提出了一种四维注意力神经网络 (4D-aNN) 用于 EEG 情绪识别, 在 SEED 数据集上的个体内划分下取得了最先进的性能, 证明了注意力机制在不同领域对 EEG 情绪识别的有效性。

本文提出了一种新颖的神经网络架构 AEE-TCNet, 融合时空卷积块、滑动窗口机制、多头注意力模块以及时间卷积网络等多模块设计, 用于解码运动想象脑电信号。该方法的主要贡献如下。

(1) 本文设计的时空卷积块提取了 EEG 数据的时间与空间特征, 还通过多层次的特征处理机制增强了模型的鲁棒性。(2) 在处理长时间序列时, 本文采用滑动窗口机制, 将输入的数据划分为多个时间片段, 每个时间窗口独立提取时间特征。(3) 为增强模型对关键信息的关注, 提出了可选的多头注意力机制模块。通过对滑动窗口内的特征加权, 突出最具判别性的特征信息, 有效提高分类性能。(4) 在每个滑动窗口的特征处理阶段, 本文采用时间卷积网络 (TCN) 进行特征学习 (模型结构如图 1 所示)。

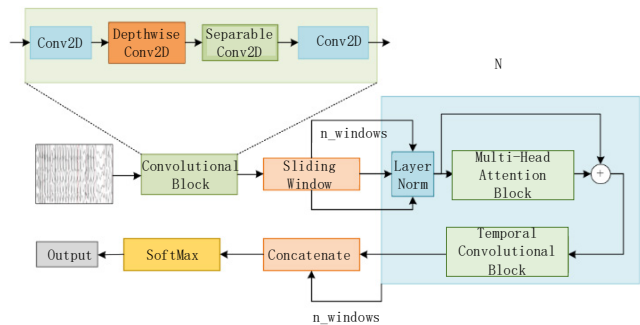


图 1 AEEG-TCNet 结构图

Fig.1 AEEG-TCNet architecture diagram

## 1 实验方法

### 1.1 数据集

本文选用了 BCI Competition IV-2a<sup>[16]</sup> 数据集对所




图 2 CV 块通过四个卷积层执行时空编码

Fig.2 CV block performs spatio-temporal encoding

提出的模型进行训练和评估。该数据集由格拉兹理工大学于 2008 年创建, 是一个广泛使用的公开运动想象脑电信号 (MI-EEG) 数据集。数据集包含 9 名受试者在完成四种不同运动想象任务时的 EEG 数据, 这四种任务分别包括左手、右手、双脚和舌头的运动。实验使用了 22 个 Ag/AgCl 电极以 250Hz 的采样率采集脑电信号。每名受试者的数据分为两个 session, 一个用于训练, 另一个用于测试, 每个 session 包含 288 次脑电试验。

### 1.2 预处理

在本文中, 原始的 MI-EEG 信号未经过预处理, 完全保留了全频段的通道信息。随后, 将由 ch (电极通道) 和 T (时间点) 组成的数据输入到本文所提出的模型中。AEEG-TCNet 模型的目标是将输入的 MI 试验  $X_i$  映射到其对应的类别  $y_i$ , 其中  $X_i \in \mathbb{R}^{C \times T}$ ,  $y_i \in \{1, \dots, n\}$ 。针对本文使用的 BCI Competition IV-2a 数据集, 参数取值为  $ch=22$  (脑电图通道数),  $T=1125$  (时间点数),  $n=4$  (MI 类别数)。

### 1.3 卷积块

卷积模块是 AEEG-TCNet 的关键组成部分, 用于对 EEG 信号进行多层次的时空特征提取。该模块通过一系列二维卷积、深度可分离卷积和可分离卷积操作, 逐步捕获信号的时间依赖性和空间分布特性, 同时采用池化和正则化方法有效降低模型复杂度并防止过拟合 (如图 2 所示)。

#### 1.3.1 时间特征提取: 二维卷积层 (Conv2D)

本文将卷积核的大小设置为  $(KernLength, 1)$ , 其中  $KernLength$  是时间维度上的卷积核长度。该设计确保了卷积操作专注于时间序列的局部模式, 而不会干扰空间维度的特征。通过设定输出通道数为  $F1$ , 这一层能够学习不同时间序列特征模式, 同时结合批量归一化 (Batch Normalization) 减少内部协变量偏移, 增强训练的稳定性。

#### 1.3.2 空间特征提取: 深度可分离卷积层 (Depthwise Conv2D)

为了提取 EEG 信号的空间特征, 使用深度可分离卷积层对每个时间点的特征图进行空间操作, 该层的卷积

核大小为  $(1, in\_chans)$ , 覆盖所有通道, 通过深度乘数  $D$  增强每个通道特征的复杂性。该层输出的特征经过批量归一化后, 应用 ELU 激活函数引入非线性能力, 并通过平均池化 (Average Pooling2D) 沿时间维度进行降采样, 从而降低特征维度, 减轻模型的过拟合风险。

#### 1.3.3 局部复杂特征提取: 可分离卷积层 (Separable Conv2D)

为了在时间和空间特征融合的基础上进一步提取复杂的局部特征, 模块中加入了可分离卷积层, 这一层的卷积核大小设定为  $(1, 16)$ , 专注于跨时间维度的局部模式, 同时将输出通道数扩展至  $F2=F1 \times D$ , 为模型提供了更强的特征表达能力。卷积结果经过批量归一化和 ELU 激活函数的处理后, 通过平均池化层进一步降维, 从而减少冗余信息。

#### 1.3.4 全局特征融合: 二维卷积层 (Conv2D)

为了对前述提取的时空特征进行整合, 模块引入了最后一层二维卷积, 该卷积层的卷积核大小为  $(16, 1)$ , 覆盖更大的时间范围, 捕获全局模式, 同时保持空间维度的信息完整。输出的通道数维持为  $F2$ , 结合批量归一化和 ELU 激活函数, 进一步提升模型的特征表达能力。经过平均池化层的降采样处理, 时间维度显著减少, 生成的高维特征张量为后续的滑动窗口机制和分类任务提供了多层次的信息支持。

### 1.4 基于卷积的滑动窗口

在深度学习中, 滑动窗口是一种广泛应用的技术, 通常用于在图像中检测目标区域。传统的滑动窗口方法通过在图像上移动一个固定大小的窗口, 并利用分类器对每个窗口内的区域进行分类, 实现目标检测<sup>[7]</sup>。相比之下, 基于卷积的滑动窗口能够更好地适应不同的数据集和检测任务, 表现出更强的泛化能力。在本文中, 滑动窗口的数量  $n\_windows$  被设置为 5, 这意味着模型将从 EEG 数据中提取 5 个不同的时间窗口进行特征处理。每个时间窗口的输出都会被单独输入到注意力模块, 以进一步突出关键信息, 增强模型对重要特征的捕捉能力, 从而提高分类性能。其中, 窗口的长度  $Lw$  如式 (1) 所示:

$$Lw = Ls - n\_windows + 1 \quad (1)$$



式中,  $L_s$  表示时间向量,  $1 \leq n\_windows < L_s$ 。

### 1.5 注意力机制

注意力机制分为自注意力机制、通道注意力机制和空间注意力机制三种类型。本文采用的是多头自注意力机制(如图3所示)。该机制通过并行学习多种关系和特征类型,不仅提升了模型的性能,还增强了对复杂模式的捕获能力<sup>[18]</sup>。自注意力层由三个核心组件构成:查询向量(Query, Q)、键向量(key, K)和值向量(value, V)。其中,查询向量和键向量之间的点积操作用于评估不同标记之间的相关性。自注意力计算公式如式(2)所示:

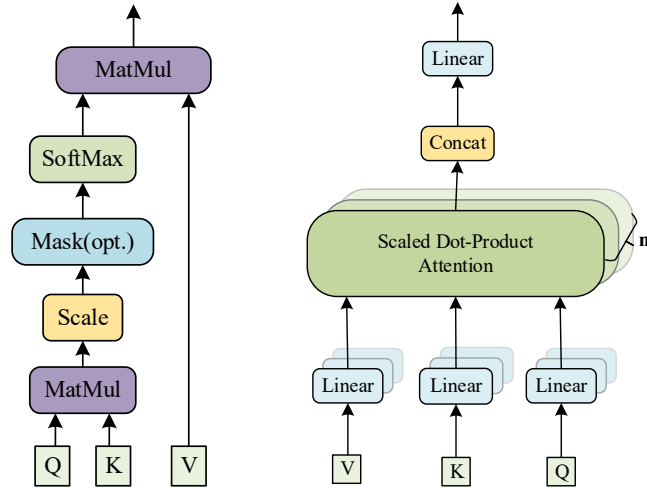
$$Attention(Q, K, V) = \text{soft max} \left( \frac{QK^T}{\sqrt{d_k}} \right) V \quad (2)$$

式中,  $Q$ 、 $K$ 、 $V$  分别代表查询(Query)、键(Key)、值(Value)矩阵;  $d_k$  是键向量的维度。多头注意力机制在自注意力的基础上,通过增加多个注意力头来并行地对输入信息进行不同纬度的注意力分配,从而获得更丰富的特征,如式(3)、式(4)所示:

$$Head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (3)$$

$$MultiHead(Q, K, V) = \text{Concat}(Head_1, \dots, Head_n) W^O \quad (4)$$

在式(3)中,  $W_i^Q$ 、 $W_i^K$ 、 $W_i^V$  分别表示第  $i$  个头的查询、键、值的变换矩阵。式(4)中,  $W^O$  是最终的输出变换矩阵;  $\text{Concat}$  表示拼接操作,其中  $i=1, \dots, n$ 。



(a) 缩放点积注意力  
(a) Zoom dot product attention

(b) 多头注意力  
(b) Multi-head attention

图3 Multi-head self-attention( $n=2$ ) 结构图

Fig.3 Multi-head self-attention ( $n=2$ ) structure diagram

### 1.6 时间卷积模块

本文中的时间卷积模块(TCN)由两个残差块组成。残差连接有助于缓解梯度消失问题,从而使得网

络能够训练得更深<sup>[19]</sup>。每个残差块包括一维因果卷积、层归一化和 ELU 激活函数(如图4所示)。因果卷积保证了输出的时间序列不会泄露未来的数据,对于时间点  $t$  的输出,它仅依赖于  $t$  时刻及其之前的输入。扩张卷积是一种卷积操作,通过在输入序列中插入空隙来扩大卷积核的感受野,从而使模型能够捕捉更长时间的依赖关系,而不会增加额外的参数。扩张卷积的感受野大小(RFS)随着残差块数量  $L$  的增加而指数性扩展, RFS 的大小由残差块数量  $L$  和卷积核大小  $K_T$  两个参数共同控制, RFS 的定义如式(5)所示:

$$RFS = 1 + 2(K_T - 1)(2^L - 1) \quad (5)$$

在本文中, TC 块使用了一个包含 32 个大小为  $K_T=4$  的卷积层的扩张卷积网络,  $L=2$  个残差块,得到扩张卷积网络的感受野大小为 19。

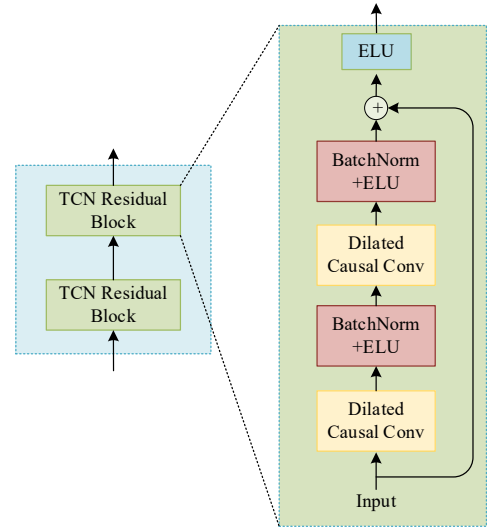


图4 时间卷积块的残差块结构图

Fig.4 Residual block structure diagram for time-convolution blocks

## 2 实验结果

### 2.1 模型评估指标

本文中的实验使用了 Python 3.10 中的 Tensorflow 库,并在 NVIDIA RTX 4060 GPU 上进行计算。所有模型均使用 Adam 优化器进行训练,学习率设置为 0.0009,批量大小为 64,训练过程持续 1000 个 epoch,并采用 300 的 patience 值进行早停,以优化交叉熵损失函数。在评估方面,本研究所提出的模型通过准确率(式6)和 Kappa 值(式7)进行性能评估。

$$acc = \frac{\sum_{i=1}^n TP_i / l_i}{n} \quad (6)$$

式中,  $TP_i$  是 true positive;  $i$  为  $i$  类中正确预测的样本数;  $l_i$  是  $i$  类中的样本数;  $n$  表示类数 ( $n=1, 2, 3, 4$ )。

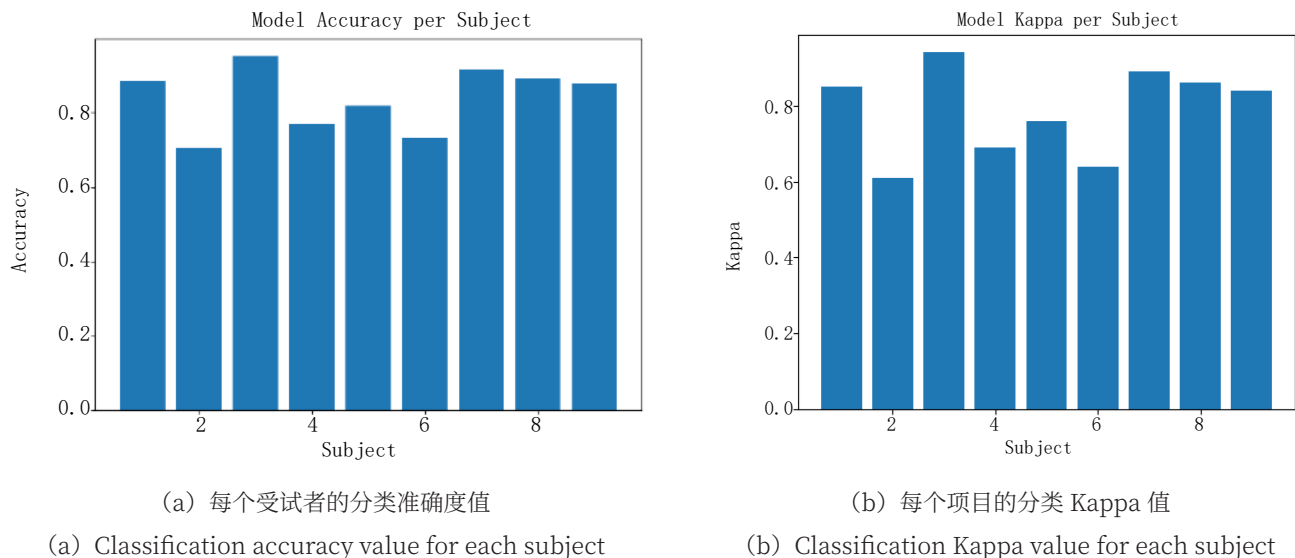


图 5 每个受试者的分类准确率和 Kappa 值

Fig. 5 Classification accuracy and Kappa value for each subject

$$Kappa = \frac{1}{n} \sum_{a=1}^n \frac{P_a - P_e}{1 - P_e} \quad (7)$$

式中,  $n$  表示类数 ( $n=1, 2, 3, 4$ );  $P_a$  表示试验的平均准确率;  $P_e$  表示与预期一致的百分比。

2.2 模型整体性能

AEEG-TCNet 在 BCI Competition IV-2a 数据集上的平均准确率为 83.9%, 平均 kappa 值为 0.79。该模型对每位受试者的分类准确率和 kappa 值表现如图 5 所示。其中, 受试者 3 在四分类任务中达到最高准确率 95.1%。相比之下, 受试者 2 的分类准确率较低, 仅为 70.5%。

2.3 与近几年研究的比较

MI 分类结果验证了本文提出的 AEEG-TCNet 模型

在 MI-EEG 数据集上的优越性能。为了进一步评估该模型的效果, 本文将 AEEG-TCNet 与 EEGNet、EEG-TCNet、TCNet-Fusion、ShallowConvNet<sup>[20]</sup> 四种 MI 分类方法进行比较, 结果如表 1 所示。

(1) EEGNet: 一种为不同 BCI 范式设计的紧凑型模型, 旨在实现对 EEG 信号的高效分类。其架构受 FBCSP 算法启发, 通过深度可分离卷积构建了一个专门针对 EEG 数据的轻量化网络。由于其紧凑的设计, EEGNet 展现了出色的鲁棒性和泛化能力, 在各种 BCI 任务中表现良好。

(2) EEG-TCNet: 是基于时间卷积网络 (TCN) 架构开发的深度学习模型, 专注于脑电信号处理和运动

表 1 使用 BCI-2a 数据集对拟议模型进行主题特定分类的性能 (acc 和 Kappa) 比较

Tab.1 Comparison of performance (acc and Kappa) for topic-specific classification of the proposed model using BCI-2a dataset

Method	Statics	Subject									
		1	2	3	4	5	6	7	8	9	Avg
EEGNet	Acc(%)	88.5	66.0	95.1	73.6	75.4	64.2	90.3	85.8	86.5	80.6
	Kappa	0.85	0.55	0.94	0.65	0.67	0.52	0.87	0.81	0.82	0.74
EEG-TCNet	Acc(%)	84.0	66.3	94.1	72.6	76.0	62.9	89.9	84.7	85.4	79.5
	Kappa	0.79	0.55	0.92	0.63	0.68	0.50	0.87	0.80	0.81	0.73
TCNet-Fusion	Acc(%)	86.1	66.0	93.4	72.6	79.9	66.7	90.3	85.8	85.4	80.7
	Kappa	0.81	0.55	0.91	0.63	0.73	0.56	0.87	0.81	0.81	0.74
ShallowConvNet	Acc(%)	84.3	54.1	87.5	63.6	67.4	54.9	88.8	76.8	74.2	72.4
	Kappa	0.79	0.39	0.83	0.51	0.57	0.39	0.85	0.69	0.65	0.63
AEEG-TCNet(Proposed)	Acc(%)	88.5	70.5	95.1	77.1	81.9	73.3	91.7	89.2	87.9	83.9
	Kappa	0.85	0.61	0.94	0.69	0.76	0.64	0.89	0.86	0.84	0.79

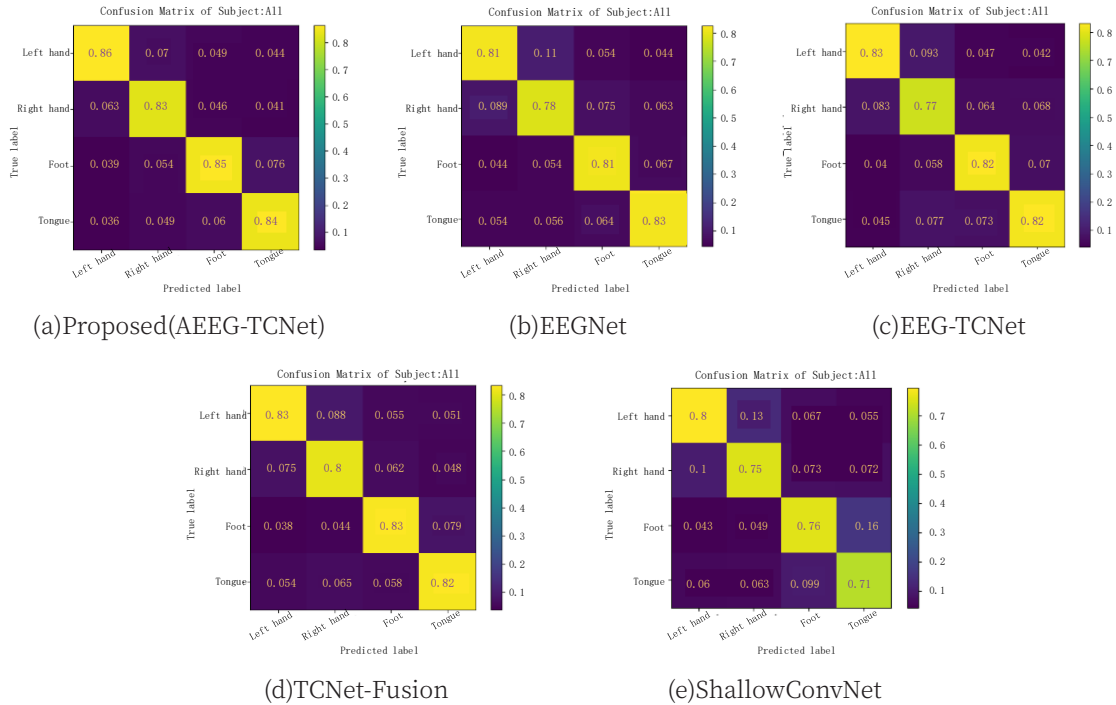


图 6 AEEG-TCNet 和再演的 EEGNet、EEG-TCNet、TCNet\_Fusion 和 ShallowConvNet 模型的分

Fig. 6 Classification confusion matrix for AEEG-TCNet and reproduced EEGNet, EEG-TCNet, TCNet\_Fusion, and ShallowConvNet models

想象分类。该模型结合了 EEGNet 的浅层特征提取能力和 TCN 对时序信息的处理能力，为 EEG 信号解码提供了更全面的特征建模。

(3) TCNet-Fusion：以时间卷积网络（TCN）为基础，并引入了融合层以增强特征表示能力，进一步提升了模型在复杂分类任务中的表现。

(4) ShallowConvNet：一种浅层卷积神经网络，其设计受到 FBCSP 算法的启发，专用于解码 EEG 信号中的频段功率特征。通过模仿 FBCSP 中的变换过程，ShallowConvNet 展现了深度学习在端到端 EEG 分析中的潜力。该模型因结构简单、参数少而具备较高的训练和推理效率。

与这些模型相比，AEEG-TCNet 模型的分类准确率提高了 3.23%。此外，AEEG-TCNet 与上述模型的平均混淆矩阵如图 6 所示。在混淆矩阵中，对角线元素表示各类的分类准确率。结果表明，AEEG-TCNet 对所有类别的 MI 解码均实现了性能提升，进一步验证了其有效性和优越性。

### 3 结语

本文提出了一种融合时空卷积和注意力机制的架构，用于解码运动想象脑电信号。该模型通过时空卷积层提取脑电信号的时间和空间特征，并引入多头注意力机制，为特征分配权重，从而提升对关键特征的捕获能

力。模型中的时间卷积层能够从时间序列中提取高级时间特征，同时结合基于卷积的滑动窗口技术，通过增强数据表征并行化特征提取过程，有效提高了 MI 分类性能。在四分类任务中，本文提出的模型实现了最高准确率 95.1% 和平均准确率 83.9%。实验结果表明，AEEG-TCNet 在 BCI Competition IV-2a 数据集上的性能优于现有多个基准模型，包括 EEGNet、EEG-TCNet、TCNet-Fusion 和 ShallowConvNet，展示了其在 MI 解码任务中的卓越表现。

AEEG-TCNet 的开发为运动想象任务的脑电信号分类提供了一种创新解决方案，展现了深度学习在脑机接口领域的巨大潜力。本文的研究不仅推动了 BCI 技术的发展，还为未来脑机接口研究提供了新的思路和方法。尽管 AEEG-TCNet 在 BCI Competition IV-2a 数据集上实现了显著的性能提升，然而为进一步验证模型的泛化能力，未来的研究还需要在更多样化的数据集上进行测试。此外，应探索更灵活的网络架构和优化策略，以进一步提升模型性能，为 BCI 领域带来更多突破。

### 参考文献

[1] ZHANG H,ZHOU Q Q,CHEN H,et al.The Applied Principles of EEG Analysis Methods in Neuroscience and Clinical Neurology[J].Military Medical Research,

- 2023,10(1):67.
- [2] SAZGAR M,YOUNG M G,SAZGAR M,et al.Overview of EEG,Electrode Placement,and Montages[J]. Absolute Epilepsy and EEG Rotation Review:Essentials for Trainees,2019:117-125.
- [3] 宋世林,张学军.脑电信号多特征融合与卷积神经网络算法研究[J].计算机工程与应用,2024,60(8):148-155.
- [4] ALTAHERI H,MUHAMMAD G,ALSULAIMAN M,et al.Deep Learning Techniques for Classification of Electroencephalogram (EEG) Motor Imagery (MI) Signals:A Review[J].Neural Computing and Applications, 2023,35(20):14681-14722.
- [5] HOSSAIN S M,AL-HAMMADI H M,MUHAMMAD G.Automatic Fruit Classification Using Deep Learning for Industrial Applications.[J].IEEE Trans.Industrial Informatics,2019,15(2):1027-1034..
- [6] 谭暑秋,凌志豪,潘嘉豪,等.面向人脸超分辨率的全局结构感知与局部增强网络[J/OL].计算机工程与应用,1-12[2024-10-29].<http://kns.cnki.net/kcms/detail/11.2127.tp.20241024.1716.012.html>.
- [7] AHMED I,DIN S,JEON G,et al.Exploring Deep Learning Models for Overhead View Multiple Object Detection[J].IEEE Internet of Things Journal,2019,7(7):5737-5744.
- [8] 许学添,蔡跃新.基于图卷积网络的运动想象识别[J].计算机工程与应用,2022,58(4):186-191.
- [9] ANG K K,CHIN Z Y,WANG C,et al.Filter Bank Common Spatial Pattern Algorithm on BCI Competition IV Datasets 2a and 2b[J].Frontiers in Neuroscience,2012, 6:39.
- [10] OLIVAS-PADILLA B E,CHACON-MURGUIA M I. Classification of Multiple Motor Imagery Using Deep Convolutional Neural Networks and Spatial Filters[J]. Applied Soft Computing,2019,75:461-472.
- [11] LAWHERN V J,SOLON A J,WAYTOWICH N R,et al.EEGNet:A Compact Convolutional Neural Network for EEG-based Brain-computer Interfaces[J].Journal of Neural Engineering,2018,15(5):056013.
- [12] MUSALLAM Y K,ALFASSAM N I,MUHAMMAD G,et al.Electroencephalography-based Motor Imagery Classification Using Temporal Convolutional Network Fusion[J].Biomedical Signal Processing and Control,2021,69:102826.
- [13] INGOLFSSON T M,HERSCHE M,WANG X,et al. EEG-TCNet:An Accurate Temporal Convolutional Network for Embedded Motor-imagery Brain-machine Interfaces[C]//2020 IEEE International Conference on Systems,Man,and Cybernetics (SMC).IEEE,2020:2958-2965.
- [14] ZHANG J,ZHENG S,CHEN W,et al.A Scheme Combining Feature Fusion and Hybrid Deep Learning Models for Epileptic Seizure Detection and Prediction[J]. Scientific Reports,2024,14(1):16916.
- [15] XIAO G,SHI M,YE M,et al.4D Attention-based Neural Network for EEG Emotion Recognition[J].Cognitive Neurodynamics,2022:1-14.
- [16] [https://www.bbc.de/competition/iv/desc\\_2a.pdf](https://www.bbc.de/competition/iv/desc_2a.pdf)
- [17] PEREA J A,HARER J.Sliding Windows and Persistence: An Application of Topological Methods to Signal Analysis[J].Foundations of Computational Mathematics,2015,15:799-838.
- [18] LI J,WANG X,TU Z,et al.On the Diversity of Multi-head Attention[J].Neurocomputing,2021,454:14-24.
- [19] BAI S,KOLTER J Z,KOLTUN V.An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling[J].arxiv Preprint arxiv: 1803.01271,2018.
- [20] WANG T,DONG E,DU S,et al.A Shallow Convolutional Neural Network for Classifying MI-EEG[C]//2019 Chinese Automation Congress (CAC).IEEE,2019:5837-5841.