

基于深度学习的运动想象脑电信号识别方法*

宋春宁, 盛 勇, 宁正高
(广西大学 电气工程学院, 广西 南宁 530004)

摘 要: 在脑电(EEG)信号分析方法中,时频分析方法综合考虑了信号的时间与频率两者的分辨率,同时改善了单纯时间域或频率域分析方法的短板。本实验使用 S 变换代替短时傅里叶变换将左右手运动想象脑电信号转换为二维时频图像形式,然后构建卷积神经网络-极限学习机(CNN-ELM)模型进行分类。在面对小样本训练数据时模型能力受到限制,提出一种数据增强方法,通过 ACGAN 对时频图像进行生成,有效丰富了训练样本数量。实验结果表明:CNN-ELM 模型识别效果好,泛化能力强,进行数据增强后识别正确率得到了进一步的提升。

关键词: 运动想象; 脑电信号; S 变换; 卷积神经网络; 极限学习机; 数据增强
中图分类号: TP391 **文献标识码:** A **文章编号:** 1000-9787(2022)04-0125-04

Deep learning-based method for recognition of motion imagery EEG signal*

SONG Chunning, SHENG Yong, NING Zhenggao
(School of Electrical Engineering, Guangxi University, Nanning 530004, China)

Abstract: Among EEG signal analysis methods, the time-frequency analysis method comprehensively considers the resolution of both the time and frequency of the signal, and improves the shortcomings of the simple time-domain or frequency-domain analysis method. In this experiment, S transform is used instead of STFT to transform left and right hand motor imagery EEG signals into two-dimensional time-frequency images, and then a CNN-ELM model is constructed for classification. When faced with the training data of small samples, the ability of the model is limited, so a data augmentation method is proposed. The generation of time-frequency images by conditional image synthesis with auxiliary classifier GANs (ACGAN) effectively enriched the number of training samples. The experimental results show that the CNN-ELM model has good recognition effect and strong generalization ability, and the recognition accuracy is further improved after data augmentation.

Keywords: motion imagery; electroencephalogram(EEG) signal; S transform; CNN; extreme learning machine (ELM); data augmentation

0 引 言

脑-机接口 (brain-computer interface, BCI) 技术是一门多学科融合的新型人机结合技术。目前较为普遍的是利用大脑特定活动产生的脑电 (electroencephalogram, EEG) 信号控制外部电子设备,其基本过程是首先使用电极采集到脑电信号,再经过放大、去噪、滤波等一系列预处理后,最后利用特征提取与分类算法将信号解码成控制设备的指令。有效提出脑电特征并准确分类是 BCI 的关键。研究发现,当人进行单侧肢体运动想象时大脑主感觉运动皮层的特定频段的能量会出现变化,这类现象被称为事件相关去同步 (event-related desynchronization, ERD) 及事件相关同步 (event-

related synchronization, ERS)^[1]。基于时频分析方法的左右手运动想象脑电信号分类效果要由于单纯的时域或频域分析方法。在基于左右手运动想象脑电信号识别方法中,文献[2]使用短时傅里叶变换 (short-time Fourier transform, STFT) 时频图像结合卷积神经网络 (convolutional neural network, CNN) 与 SAE (stacked autoencoder) 模型,其识别效果优于普通 CNN; 文献[3]使用小波变换时频图像结合 CNN 进行分类,使用 C3 及 C4 电极进行实验,验证了添加 CZ 电极会降低分类器的识别效果。文献[4]使用 STFT 时频图像结合 CNN 与支持向量机 (support vector machine, SVM),效果优于传统的滤波器组共空间模式 (filterbank common

收稿日期:2020-08-05
* 基金项目:国家自然科学基金资助项目(51767005); 广西自然科学基金资助项目(2016GXNSFAA380328)

spatial pattern, FBCSP),但其分类耗时较高。传统的时间-频率方法主要包括:STFT、小波变换(wavelet transform, WT)、S变换(S transform)等。

由于 STFT 窗函数宽度固定不变,窗太窄虽然会有高的时间分辨率但会导致频率分辨率差;窗太宽则会导致时间分辨率过低,不利于脑电信号的时频特征提取。WT 的分析结果并不是真正的时间-频率谱,从而导致信号特征的精确度有一定的问题。S 变换是 STFT 与 WT 的继承与发展,加入了 WT 法的多分辨率分析思想,有效克服了 STFT 时窗固定的缺点,能较好地适应非平稳信号。S 变换能同时在时域和频域内提供信号良好的局部时频特征,因此,它适用于具有特定节律特征的运动想象脑电信号的分析,而且还不需要考虑小波基函数选择问题。

CNN 是一种非常有效的图像识别方法,在语音识别、计算机视觉、图像处理等方面取得了不错的成绩,在脑电信号分类领域也有研究^[5-7]。通常 CNN 的最后一层可以看成是一个线性分类器,但却不是一个最优的分类器。Huang G B 等人^[8]在 2004 年提出了一种单隐层网络学习算法,称为极限学习机(extreme learning machine, ELM),与传统的单隐层网络相比,ELM 在保证学习精度的前提下比传统的学习算法速度更快,泛化性能好等优点。针对 CNN 泛化能力稍差、较易陷入局部极值点的不足之处,本文采用 CNN 和 ELM 相结合的方法,使用 ELM 取代 CNN 的最后一层。

在脑电信号采集过程中,受试者受疲劳和精力分散的影响,很难长时间保持良好的实验状态,很难获得足够和优质的被试标记数据。在分类问题中,分类模型面对小样本训练集能力往往受到限制。文献[9]使用高斯噪声作为信息源输入进一个基于快速傅里叶变换(FFT)的系统来产生脑电信号,但此方法忽视了脑电信号的时域特性。文献[10]将不同时间段的脑电信号进行拼接构造新的数据,虽然保持了时域特征然而忽视了脑电信号的频域特性。

针对以上问题本文提出一种基于 ACGAN (auxiliary classifier generative adversarial networks)的数据增强方法,即使用 ACGAN 模型进行时频特征图像的扩增来提高小样本数据下分类模型的性能。

1 S 变换基本原理

S 变换是地球物理学家 Stockwell R G 在 1996 年提出的,是连续 WT 和 STFT 的发展,适用于非平稳信号的分析^[11]。

信号 $X(t)$ 的 S 变换定义如下

$$S(\tau, f) = \int_{-\infty}^{\infty} X(t) \omega(\tau - t, f) e^{-j2\pi ft} dt \tag{1}$$

$$\omega(\tau - t, f) = \frac{|f|}{\sqrt{2\pi}} \exp(-\frac{f^2(\tau - t)^2}{2}) \tag{2}$$

式中 $\omega(\tau - t, f)$ 为高斯窗口, f 为频率, τ 为控制高斯窗口

关于时间轴 t 的位置参数。

其逆变换公式如下

$$X(t) = \int_{-\infty}^{\infty} [\int_{-\infty}^{\infty} S(\tau, f) d\tau] e^{j2\pi ft} df \tag{3}$$

由式(1)和式(2)可知, S 变换是在继承 STFT 原理的基础上采用了宽度可变的高斯窗函数。高斯窗函数 $\omega(t, f)$ 是时间和频率的函数,窗宽与频率呈反比,这使得窗函数在低频区域具有良好的频率分辨率,在高频区域具有良好的时间分辨率。

2 CNN-ELM 网络结构

2.1 ELM

ELM 网络结构如图 1 所示。




图 1 ELM 模型

对于给定样本 $(x_i, y_i) \in R^n \times R^m (i=1, 2, \dots, N)$, 有激励函数为 $g(a_i, b_i, x)$ 和隐节点数目 L 个, ELM 网络模型可以表示为

$$O_j = \sum_{i=1}^L \beta_i g(a_i \cdot x_i + b_i), j=1, 2, \dots, N \tag{4}$$

式中 a_i 为输入权值; b_i 为隐含层的偏差; β_i 为连接隐含层与输出层的输出权值; $O_j \in R^m$ 为网络输出值。当激励函数 g 能够以零误差逼近任意 N 个样本时, 可以将式(4)表示为矩阵形式

$$H\beta = T \tag{5}$$

$$H = \begin{pmatrix} g(a_1 \cdot x_1 + b_1) & \cdots & g(a_L \cdot x_1 + b_L) \\ \vdots & & \vdots \\ g(a_1 \cdot x_N + b_1) & \cdots & g(a_L \cdot x_N + b_L) \end{pmatrix}_{N \times L} \tag{6}$$

式(6)等价于求解 $H\beta = T$ 的最小二乘解, 即寻找最优的输出权值 β 为

$$\beta = H^+ T \tag{7}$$

式中 $H^+ = H^T (HH^T)^{-1}$ 为隐含层输出矩阵 H 的广义逆矩阵。

2.2 CNN-ELM 结构与参数

本文将 CNN 与 ELM 相结合, 将 ELM 取代 CNN 的最后一层, 其结构如图 2 所示。




图 2 CNN-ELM 模型结构

本文 CNN 两个卷积层分别使用不同形状的卷积核, 以

便更好地提取图像特征。网络模型第 1 层为输入层,输入图像大小为 48×46 ;第 2 层为卷积层,该层有 8 个卷积核,其卷积核的大小为 $[3 \times 3]$,设置步长为大小为 $[1 \times 2]$,使用二维卷积核是为了更好地提取图像的时频特性;第 3 层为最大池化层,大小为 $[2 \times 2]$;第 4 层为卷积层,该层有 8 个卷积核,卷积核的大小为 $[23 \times 1]$;最后为 ELM。网络的训练过程如下:先采用梯度下降法调整 CNN 的参数,当训练误差小于一定值时停止训练,之后将 CNN 全连接层提取的特征作为 ELM 的输入用于 ELM 的训练。当 ELM 训练完成后,将它取代训练完成的 CNN 的最后一层,整个分类网络也就形成了。

3 实验 ACGAN 模型结构与参数

ACGAN 是在 GAN 的基础上由 Odena A 等人^[12]在 2016 年提出的一种新的辅助标签 GAN。ACGAN 损失函数包含两部分第一部分 L_s 是面向数据真实与否的最大似然估计如式(8),第二部分 L_c 则是面向数据分类准确性的最大似然估计如式(9)。在 ACGAN 的训练中,优化的方向是希望判别器使得 $L_s + L_c$ 尽可能大,而生成器使得 $L_s - L_c$ 尽可能大。式(8)、式(9)如下

$$L_s = E[\log P(S = real | X_{real})] + E[\log P(S = fake | X_{fake})]$$

(8)

$$L_c = E[\log P(C = c | X_{real})] + E[\log P(C = c | X_{fake})]$$

(9)

表 1 实验使用的 ACGAN 其具体的结构如表 1 所示。ACGAN 的输入、输出图像大小均为 48×46 。模型训练批量大小为 30,生成器第一层为全连接层输出尺寸为 (30,24,23,128);第二层为上采样层输出尺寸为 (30,48,46,128);第三层为卷积层输出尺寸为 (30,48,46,128);第四层为卷积层输出尺寸大小为 (30,48,46,64);第五层为卷积层输出尺寸大小为 (30,48,46,1)。判别器第一层为卷积层输出尺寸大小为 (60,24,23,32);第二层为卷积层输出尺寸大小为 (60,12,12,64);第三层为卷积层输出尺寸大小为 (60,6,6,128);第四层为两个全连接层,神经元个数分别为 1(判断真假)和 2(2 分类)。

表 1 本文 ACGAN 的生成器与判别器结构

层数	生成器结构	判别器结构
1	全连接层	卷积层:32 个卷积核,[3,3]
2	上采样层	卷积层:64 个卷积核,[3,3]
3	卷积层:128 卷积核,[3,3]	卷积层:128 个卷积核,[3,3]
4	卷积层:64 卷积核,[3,3]	全连接层
5	卷积层:1 卷积核,[3,3]	

4 实验过程与结果分析

4.1 实验数据来源

实验采用的左右手运动想象脑电数据来自 BCI Competition II,BCI Competition III 和 BCI Competition IV。前一数

据集共包含一名女性受试者,该实验的任务是按照箭头提示进行左右手运动想象来控制一个反馈条移动,每 9 s 采集一次,所有的试次(Trials)均在同一天完成,总共 280 个试次,其中想象左右手运动各 140 个试次。实验采集了 C3, C4,CZ 三个电极的脑电信号,信号的频率为 128 Hz。三个数据集的实验过程的详细描述,如文献[13]所述。实验选取 C3,C4 电极的 8 ~ 13 Hz 及 18 ~ 24 Hz 频段图像进行组合,其大小为尺寸 48×46 ,组合图像如图 3 所示。




图 3 组合特征图像

4.2 CNN-ELM 实验结果

为检验本文方法的性能,选用 BCI Competition II 竞赛数据采用五折交叉验证法和训练集测试集比例 1:1 分别进行实验。实验结果如表 2 所示,该表选用对应文献中的最优结果。STFT + CNN-SAE 是文献[2]中采用的方法,先用 STFT 方法进行时频特征提取,然后使用 CNN-SAE 模型进行特征分类。WT + CNN 是文献[3]中采用的方法,先用 WT 方法进行时频特征提取,然后使用 CNN 模型进行特征分类。文献[14]使用 WT 结合小波神经网络(wavelet neural network,WNN),由于存在过拟合问题,进行数据增强后识别率为 91.1 %。由表 2 可以看出本文模型的识别率要优于文献[2]和文献[3]及文献[14]所提出的方法的识别率。

表 2 BCI Competition II 数据识别率

文献	方法	最高分类正确率/%
[2]	STFT + CNN-SAE(1:1)	90.00
[3]	WT + CNN(5-fold cross-validation)	92.75
[14]	WT + WNN(1:1)	91.10
本文方法	训练比例(1:1),(5-fold cross-validation)	92.10,94.64

在 BCI Competition III 数据集上,分别选取被试者 O3, S4,X11 分别选取 320,540,540 个样本采用五折交叉验证法进行实验。表 3 列举了不同文献在上的识别率,可见本文的识别率要优于其他方法。

表 3 BCI Competition III 数据识别率

方法	O3	S4	X11	Avg
文献[15]	86.80	75.90	75.40	79.36
文献[16]	89.30	72.96	75.18	78.96
文献[17]	82.39	83.89	78.15	81.47
本文方法	92.20	79.60	78.70	83.50

4.3 数据增强实验

实验选用 BCI Competition IV 数据集中 5 名受试者进行实验。数据增强实验分为训练过程与测试过程。训练过程将由 ACGAN 的生成器产生出新的样本数据,新数据用于扩增原始数据后用于分类器的训练。测试过程使用训练好的分类器对测试集进行预测,从而得出分类器在测试集上的识别准确率。选取每名受试者 200 个样本作为训练集用于训练 ACGAN,其余 520 个样本作为分类器的测试集。

为了验证数据增强的效果,实验扩增了原始的 200 个数据,分别加入了新的 200,400,600,800 个新生成的样本,其实验结果如表 4 和图 4 所示。表 4 列出了 5 名受试者在不同扩增数据下的平均识别正确率,可知原始数据未扩增时分类器的平均识别正确率为 76.3%,当扩增 400 个样本时平均识别正确率 78.2% 达到最大。从图 4 可以直观看出最初加入 200 个新样本受试者 B04,B05,B08 以及 B09 在测试集上的识别正确率得到了提升,而在之后随着生成样本的加入各位受试者的识别正确率走势也有所不同。当加入的生成样本远大于原始样本时分类器更多的去拟合生成样本的分布,而一定程度上忽视了原始样本的分布,观察平均识别正确率可知,当添加的新样本数量大于 600 时识别正确率会逐渐降低。

表 4 数据增强实验结果

	B04	B05	B07	B08	B09	Avg
Raw	84.6	72.1	69.0	80.8	74.8	76.3
+200	85.6	75.0	68.8	81.5	76.3	77.4
+400	87.0	74.2	70.4	83.3	76.0	78.2
+600	86.3	73.4	70.6	83.7	76.0	78.0
+800	86.3	71.2	68.3	83.3	74.6	76.7




图 4 数据增强实验结果

5 结束语

基于运动想象的 BCI 是众多 BCI 范式中的重要组成部分,提高脑电信号的识别精度是 BCI 技术从实验室研究走向实际应用的关键之一。本文研究了利用 ELM 方法实现左右手运动想象脑电信号的自动分类。采用的 CNN-ELM 模型具有模型简单,准确率高的特点,采用的数据增强方法丰富了小样本数据集样本的数量提高了识别率。实验表明 CNN 结合 ELM 提高了识别率,具有较好的泛化性能,在一定程度上满足了更高要求 BCI 系统的需求。

参考文献:

[1] NEUPER C,PFURTSCHELLER G.15 Event-related desynchronization (ERD) and synchronization (ERS) of rolandic EEG rhythms during motor behavior[J]. International Journal of Psychophysiology,1998,30(1-2):7-8.

[2] TABAR Y R,HALICI U. A novel deep learning approach for classification of EEG motor imagery signals[J]. Journal of Neural Engineering,2017,14(1):016003.1-016003.11.

[3] XU B G,ZHANG L L,SONG A G,et al. Wavelet transform time-frequency image and convolutional network based motor imagery EEG classification[J]. IEEE Access,2018,7:6084-6093.

[4] 胡章芳,张力,黄丽嘉,等. 基于时频域的卷积神经网络运动想象脑电信号识别方法[J]. 计算机应用,2019,39(8):2480-2483.

[5] CHAUDHARY S, TARAN S, BAJAJ V, et al. Convolutional neural network based approach towards motor imagery tasks EEG signals classification[J]. IEEE Sensors Journal,2019,19(12):4494-4500.

[6] HE K,ZHANG X,REN S,et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence,2014,37(9):1904-1916.

[7] 王卫星,孙守迁,李超,等. 基于卷积神经网络的脑电信号上肢运动意图识别[J]. 浙江大学学报(工学版),2017,51(7):1381-1389.

[8] HUANG G B,ZHU Q Y,SIEW C K. Extreme learning machine: A new learning scheme of feedforward neural networks[C]// 2004 Proceedings of 2004 IEEE International Joint Conference on Neural Networks,IEEE,2004:985-990.

[9] PARIS A, ATIA G K, VOSOUGHI A, et al. A new statistical model of electroencephalogram noise spectra for real-time brain-computer interfaces[J]. IEEE Transactions on Biomedical Engineering,2017,64(8):1688-1700.

[10] FABIEN L. Generating artificial EEG signals to reduce BCI calibration time [C] // 5th International Brain-Computer Interface Workshop, Graz, Austria,2011:176-179.

[11] STOCKWELL R G, MANSINHA L, LOWE R P. Localization of the complex spectrum: The S transform[J]. IEEE Transactions on Signal Processing,2002,44(4):998-1001.

[12] ODENA A,OLAH C,SHLENS J. Conditional image synthesis with auxiliary classifier GANs[C]//2017 34th Int'l Conf on Machine Learning(ICML),2017:4043-4055.

[13] 杨默涵. 基于运动想象的脑电信号分类算法与脑-机接口技术研究[D]. 长春:吉林大学,2017.

[14] ZHANG Z W, DUAN F, SOLE-ASALS C J, et al. A novel deep learning approach with data augmentation to classify motor imagery signals[J]. IEEE Access,2019,7:15945-15954.

或吸除。

表 4 垃圾数量及其加权总值

垃圾种类		垃圾数量	加权总值
无机垃圾(废塑料、烟头)	小	3	3
	中	0	0
	大	0	0
有机垃圾(纸巾)	小	3	6
	中	0	0
	大	0	0
未收集的清扫垃圾(灰尘堆)		1	6
黏性残留物(黏性污渍)		3	6
合计		10	21

4 结 论

通过自建数据集来训练地面垃圾检测模型,实验检测结果表明:模型在测试集上的 mAP 达到了 88.3%,平均帧率达到了 28 帧/s,基本能够满足地面垃圾检测的要求。在实际场地测试中实现了对地面垃圾的分类与量化,评定出了清洁度等级,以便于清洁机器人高效地完成定点清洁、再次清洁以及分类清洁等作业。本文为了避免机器人盲目清洁作业而浪费时间和资源提供了一种解决方案。未来研究可以增加实际的垃圾类别与场景,提高垃圾检测模型对各种垃圾特征和属性的检测适应性,使清洁机器人达到更高效、更高质量的自主和协作作业能力。

参考文献:

[1] PRABAKARAN V, ELARA M R, PATHMAKUMAR T, et al. Floor cleaning robot with reconfigurable mechanism[J]. Automation in Construction, 2018, 91: 155–165.

[2] 张一博,马磊. 基于视觉传感器的移动机器人定位算法[J]. 传感器与微系统, 2019, 38(6): 137–143.

[3] 巨志勇,张文馨,翟春宇. 基于改进 Canny 算子的垃圾图像边缘检测[J]. 电子科技, 2020(8): 1–6.

[4] GUO S, HAN L, HAO X. GW28-e0419 Image detection scale-invariant feature transform algorithm based on feature matching improves image matching accuracy[J]. Journal of the American College of Cardiology, 2017, 70(16): C10.

[5] LI W, LIU K, YAN L, et al. FRD-CNN: Object detection based on small-scale convolutional neural networks and feature reuse[J]. Scientific Reports, 2019, 9(1): 98–136.

[6] HUANG G, LIU Z, MAATEN L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE Computer Socie-

ty Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 4700–4708.

[7] PHAM C, JEON J W. Robust object proposals re-ranking for object detection in autonomous driving using convolutional neural networks[J]. Signal Processing: Image Communication, 2017, 53: 110–122.

[8] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137–1149.

[9] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV), Santiago, 2015: 1440–1448.

[10] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, 2016: 779–788.

[11] REDMON J, FARHADI A. YOLO9000: Better, faster, stronger[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 6517–6525.

[12] REDMON J, FARHADI A. YOLOv3: An incremental improvement[D]. Washington: University of Washington, 2018.

[13] 何东健,刘建敏,熊虹婷,等. 基于改进 YOLO v3 模型的挤奶奶牛个体识别方法[J]. 农业机械学报, 2020, 51(4): 250–260.

[14] ZHANG X, YANG W, TANG X, et al. A fast learning method for accurate and robust lane detection using two-stage feature extraction with YOLO v3[J]. Sensors, 2018, 18(12): 4308.

[15] LI J, GU J, HUANGZ, et al. Application research of improved YOLO V3 algorithm in PCB electronic component detection[J]. Applied Sciences, 2019, 9(18): 3750.

[16] 潘卫国,刘博,陈英昊,等. 基于 YOLO v3 的交通标志牌检测识别[J]. 传感器与微系统, 2019, 38(11): 147–150.

[17] SEVILLA A, RODRÍGUEZ M L, GARCÍA-MARAVÉ Á, et al. An index to quantify street cleanliness: The case of Granada[J]. Waste Management, 2013, 33(5): 1037–1046.

作者简介:

王一田(1994—),男,硕士研究生,研究方向为机器人技术,深度学习。

唐开强(1992—),男,通讯作者,博士研究生,研究方向为机器学习,机器人技术。

留沧海(1966—),男,博士,教授,主要研究领域为机电一体化,机器人技术。

(上接第 128 页)

[15] LOTTE F, LÉCUYER A, LAMARCHE F, et al. Studying the use of fuzzy inference systems for motor imagery classification[J]. IEEE Trans Neural Syst Rehabil Eng, 2017, 15(2): 322–332.

[16] ZHONG M J, LOTTE F, GIROLAMI M, et al. Classifying EEG for brain computer interfaces using Gaussian processes[J]. Pattern Recognition Letters, 2008, 29(3): 354–359.

[17] HOSSEIN B, WARD R K, BIRCH G E, et al. Comparing different classifiers in sensory motor brain computer interfaces[J]. PLOS ONE, 2015, 10(6): e0129435.

作者简介:

宋春宁(1969—),男,副教授,研究领域为模式识别,嵌入式系统。

盛 勇(1995—),男,硕士,研究方向为脑电信号分析,深度学习。

宁正高(1992—),男,硕士,研究方向为智能控制,信号处理。