

用于抑郁症脑电数据增强的卷积注意力扩散模型

汪子凯, 陈景霞, 贾晓雯, 赵 晨

(陕西科技大学电子信息与人工智能学院, 陕西 西安 710021)

✉ 221612066@sust.edu.cn; chenjingxia@sust.edu.cn; 221612107@sust.edu.cn; 221612091@sust.edu.cn



摘 要:为了解决抑郁症检测中由于脑电(Electroencephalogram, EEG)信号数据稀缺导致的分类精度不高的问题,结合去噪扩散概率模型(Denoising Diffusion Probabilistic Model, DDPM)和卷积注意力机制(Convolutional Block Attention Module, CBAM),提出了一种用于 EEG 数据增强的卷积注意力扩散模型(Convolutional Attention Diffusion Model, CADM)。在 MODMA 数据集上,生成了与原始 EEG 信号数据分布相似的时频特征,以扩充训练数据集,并利用 Vision Transformer、MLP 和 SVM 模型进行抑郁症分类。实验结果显示,增强后的数据集在 3 个分类器上的准确率分别提高了 10.99%、3.88% 和 5.50%,证明模型生成的特征具有良好的鲁棒性,有效提升了 EEG 抑郁症检测的准确性和稳定性。

关键词:脑电信号;抑郁症检测;去噪扩散概率模型;数据增强;卷积注意力模块

中图分类号:TP391 **文献标志码:**A

Convolutional Attention Diffusion Model for EEG Data Augmentation in Depression Detection

WANG Zikai, CHEN Jingxia, JIA Xiaowen, ZHAO Chen

(School of Electronic Information and Artificial Intelligence, Shaanxi University of Science & Technology, Xi'an 710021, China)

✉ 221612066@sust.edu.cn; chenjingxia@sust.edu.cn; 221612107@sust.edu.cn; 221612091@sust.edu.cn

Abstract: To address the issue of low classification accuracy caused by scarce EEG data in depression detection, this paper proposes a Convolutional Attention Diffusion Model (CADM) for EEG data augmentation by integrating Denoising Diffusion Probabilistic Models (DDPM) and Convolutional Block Attention Module (CBAM). Using the MODMA dataset, the model generates time-frequency features consistent with the distribution of original EEG data to expand the training dataset. Classification was then performed using Vision Transformer, MLP, and SVM models. Experimental results demonstrate that the augmented dataset improved classification accuracy by 10.99%, 3.88% and 5.50% across the three classifiers respectively. This proves the model's robustness in feature generation and its effectiveness in enhancing the accuracy and stability of EEG-based depression detection.

Key words: EEG signals; depression detection; denoising diffusion probabilistic models (DDPM); data augmentation; convolutional block attention module (CBAM)

0 引言(Introduction)

近年来,基于生理数据的抑郁症检测研究备受关注,其中,脑电图(EEG)因能实时反映大脑活动,被视为抑郁症诊断的有效生物标志物^[1]。然而,EEG 数据采集复杂、成本昂贵且易受

环境噪声影响,标记数据稀缺,限制了其在深度学习模型的应用。为解决数据稀缺问题,传统的数据增强方法(如翻转、缩放、噪声注入等)^[2-4]被用于 EEG 数据增强,但这些简单变换难以捕捉数据的深层特征。

收稿日期:2024-08-29

基金项目:国家自然科学基金项目(61806118);陕西科技大学博士科研启动基金项目(2020 BJ-30)

生成对抗网络 (Generative Adversarial Networks, GANs)^[5]通过学习数据概率分布来生成样本,已在 EEG 数据增强中取得一定进展。LUO 等^[6]提出的利用 SWGAN 生成 EEG 数据显著提升了情绪识别模型的性能。FAHIMI 等^[7]利用 DCGAN 框架生成人工 EEG 数据,提高了分类性能。然而, GANs 训练易出现模式崩溃,导致生成数据缺乏多样性。扩散模型作为新型生成模型,通过扩散和逆向去噪过程生成样本,表现出更稳定的训练效果和更高的样本多样性^[8]。DUAN 等^[9]提出的 DS-DDPM 模型有效提高了 EEG 信号的重建质量。TORMA 等^[10]建立的扩散概率模型生成了高质量的 EEG 数据并提升了分类性能。

尽管如此,生成的 EEG 数据仍存在信噪比低、噪声和伪影多等问题。本文提出一种结合卷积注意力机制的扩散模型,通过去噪过程提升 EEG 数据生成质量,利用卷积注意力机制捕捉数据的时空特征,进而提高基于 EEG 的抑郁症检测的准确性和稳定性。

1 本文方法(Methods of study)

1.1 用于脑电数据增强的扩散模型

由于 EEG 数据采集困难,数据集规模较小,从而导致通过深度神经网络进行抑郁症检测的精度和稳健性较差。针对以上问题,本文提出了一种用于脑电数据增强的扩散模型,该模型以去噪扩散概率模型^[11]为骨干网络,用于生成高质量的脑电数据特征。本文构建的扩散模型使用参数化马尔可夫链和变分推理来生成与真实数据匹配的合成样本,如图 1 所示。它主要包含了前向过程和反向过程。通过马尔可夫链将起始状态转化为易于处理的噪声的过程称为前向扩散过程;将噪声梯度逐步采样为信号起始状态的过程称为反向去噪过程。首先,通过预处理和短时傅里叶变换,将原始 EEG 数据转换为 EEG 时频特征,将其作为起始状态并送入扩散模型。扩散模型将先验数据分布通过前向过程逐步添加噪声,经过 T 次噪声添加,最终转换为随机噪声。再通过反向过程逐步去噪,来重建与先验分布相同的全新样本。

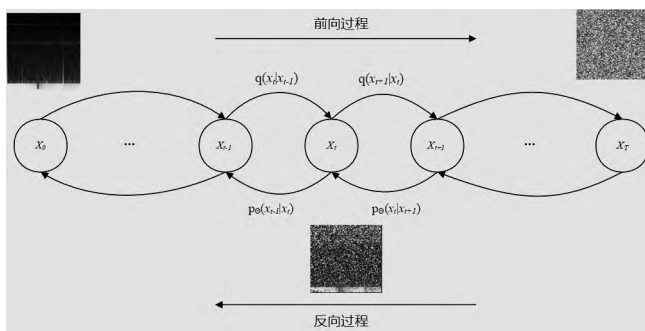


图 1 扩散模型的前向和反向过程

Fig. 1 Diffusion model of forward and backward processes

扩散过程就是对数据逐步加噪的过程,给定原始脑电数据样本 $x_0 \sim q(x)$,将少量的高斯噪声按照时间步长 t 逐步添加到样本中,产生一系列的噪声样本 x_t 。随着 t 的不断增大,噪声数据逐步接近完全高斯分布。因为 x_{t+1} 都是在 x_t 上加噪得到的,且只受 x_t 的影响,因此扩散过程被定义为一个固定马尔可夫链:

$$q(x_1, \dots, x_T | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}) \quad (1)$$

其中:每一个时刻 t 的 $q(x_t | x_{t-1})$ 都满足高斯分布。

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1-\beta_t} x_{t-1}, \beta_t I) \quad (2)$$

其中: β_t 是一个按照参数表单调递增的常数,它主要用于控制每次增加的噪声的大小。

根据重参数化技巧,令 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$,则将公式(2)转化为:

$$q(x_t | x_0) = N(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I) \quad (3)$$

通过式(3)可知,基于 x_0 并不需要经过 t 步的噪声添加一步就可以得到 x_t ,从而提高了计算效率。

反向过程的目的就是推算出条件概率 $q(x_{t-1} | x_t)$,这样就可以从高斯噪声中逐步重新创建真实样本,由于 $q(x_{t-1} | x_t)$ 无法直接计算得到,可以采用深度网络得到的 $p_\theta(x_{t-1} | x_t)$ 去替代 $q(x_{t-1} | x_t)$,因此,反向过程的马尔可夫链由 θ 参数化为

$$p_\theta(x_0, \dots, x_{T-1} | x_T) = \prod_{t=1}^T p_\theta(x_{t-1} | x_t) \quad (4)$$

其中: x_T 是满足 $N(0, I)$ 的高斯分布的,并且转移概率 $p_\theta(x_{t-1} | x_t)$ 被参数化为具有共享参数 θ 的高斯分布:

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \sigma_\theta(x_t, t)^2 I) \quad (5)$$

其中:根据推理可得高斯分布中参数化均值 $\mu_\theta(x_t, t)$ 和方差 $\sigma_\theta(x_t, t)^2$ 的数学形式为

$$\begin{aligned} \mu_\theta(x_t, t) &= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \dot{\theta}_\theta(x_t, t) \right), \\ \sigma_\theta(x_t, t)^2 &= \frac{1-\bar{\alpha}_{t-1}}{1-\alpha_t} \beta_t, \end{aligned} \quad (6)$$

其中: $\dot{\theta}_\theta(x_t, t)$ 是一个噪声预测网络,它有两个参数:噪声数据分布 x_t 和扩散步长 t 。根据 x_t 和 t 预测随机噪声 $\dot{\theta}_t$ 便可以得到 $p_\theta(x_{t-1} | x_t)$ 的完整表达式,进而可以逐步得到原始数据分布 x_0 。

网络的训练目的是使预测的噪声分布和当前时刻 t 的实际噪声分布相似,通过变分法可以得到在每一个时间步优化下列目标函数:

$$L_t^{\text{simple}} = \|\bar{\epsilon}_t \bar{\epsilon}_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t} \bar{\epsilon}_t, t)\|^2 \quad (7)$$

1.2 引入卷积注意力机制的噪声预测网络

由 1.1 节可知扩散模型的核心是训练一个噪声预测网络,该网络需要在特定的时间步长下获取带噪声的特征,并返回预测的噪声。预测噪声是具有与输入数据相同大小的张量,网络需要接收和输出相同形状张量,因此,在架构方面,本文选择构建一个 U-Net 网络作为噪声预测网络。为了让神经网络能够捕获数据的通道信息和不同位置的空间信息,本研究在噪声预测网络 U-Net 嵌入了卷积注意力机制。它结合了通道注意力和空间注意力机制,使得神经网络可以提取更多重要的特征信息并增强网络性能,能够更加准确地预测噪声分布。

本文构建的噪声预测网络如图 2 所示。和典型的 U-Net 网络一样,本网络由 4 个下采样模块、1 个中间模块和 4 个上采样模块组成,同时,在每一个块内嵌入时间步长 t ,其目的是模拟一个随时间变化噪声扰动逐渐增强的过程。除了最后一个下采样模块,每一个下采样模块包含两个残差块、一个注意力块和下采样块。逐步降低特征空间的大小,就像自动编码器一

样,然后经过中间层,确保网络只学习最重要的信息,再通过上采样模块进行上采样。在每一个下采样模块和上采样模块之间引入了残差连接,极大地改善了梯度流。




图2 噪声预测网络结构

Fig. 2 Noise prediction network structure

通道注意力模块的处理过程如图3所示,其主要作用是根据输入的特征图,在通道维度上对其进行加权处理,以突出重要的通道信息,有助于网络更好地捕捉到不同通道中的关键信息。首先,将输入的 EEG 时频特征图 F 分别经过自适应平均池化和自适应最大池化,将特征图的高度和宽度降为 1,但通道数保持不变,生成两张特征图:平均池化图 CAP 和最大池化图 CMP。平均池化和最大池化后的特征向量,再分别经过一个共享全连接层(Shared MLP)。这个全连接层用于学习每个通道的注意力权重。通过学习,网络可以自适应地决定哪些通道对于当前任务更加重要。然后,将全局最大特征向量和平均特征向量相交,得到最终注意力权重向量。最终应用 Sigmoid 激活函数来产生通道注意力权重,将这个权重与原始时频特征图 F 的每个通道相乘,得到注意力加权后的通道注意力图,计算过程为

$$M_c(F) = S(MLP(AP(F); MP(F))) \\ = S(W_1(W_0(CAP)) + W_1(W_0(CMP))) \quad (8)$$

其中: S 代表 Sigmoid 激活函数, AP 代表平均池化, MP 代表最大池化, W_0 和 W_1 分别为共享全连接层的第 1 层和第 2 层。




图3 通道注意力机制

Fig. 3 Channel attention mechanism

图4展示了空间注意力模块,其主要功能是提取输入特征不同空间位置之间的关系,能够帮助模型集中注意力于特征图中的关键区域,从而提高模型对目标的识别性能。首先,对输入特征图 F' 分别进行平均池化和最大池化操作,得到关于平均值的特征图 SAP 和关于最大值的特征图 SMP。然后,将这两个特征图沿着通道维度进行连接,得到一个具有不同尺度上下文信息的特征图。接着,通过 7×7 的卷积层处理这个特征

图,以生成空间注意力权重。然后,对生成的空间注意力权重应用 Sigmoid 激活函数,再将得到的空间注意力权重应用于原始特征图,对每个空间位置的特征进行加权。其计算过程为

$$M_s(F') = S(F(\text{cat}(AP(F'), MP(F')))) \\ = S(F(\text{cat}(SAP, SMP))) \quad (9)$$

其中: S 代表 Sigmoid 激活函数, AP 代表平均池化, MP 代表最大池化, cat 为拼接操作, F 为一个 7×7 的卷积运算。




图4 空间注意力机制

Fig. 4 Spatial attention mechanism

2 模型评估 (Model evaluation)

2.1 数据集与数据预处理

本文实验所使用的数据集是兰州大学可穿戴装备重点实验室公开的用于精神障碍分析的 MODMA 数据集^[12],它是在一个安静、干净、隔音和无电磁干扰的房间里收集的,包括来自临床抑郁症患者和匹配的健康对照者的脑电图和口语数据记录,这些受试者由医院的专业精神病学家仔细诊断和选择。其中,EEG 数据集使用传统由 128 个电极安装的弹性帽和用于普适计算应用的可穿戴 3 电极 EEG 收集器收集。本实验使用包含 53 名受试者(包括 24 名被诊断为抑郁症的门诊患者以及 29 名健康对照者)处于静息状态和进行探针任务时记录的 128 导脑电信号;重度抑郁症患者均为兰州大学第二医院的住院患者或门诊患者,并由至少一名临床精神科医生诊断,患者排除了其他精神类疾病且未接受过精神药物治疗。对于健康对照组,排除了个人或家族精神障碍史,保证了数据的真实性以及可靠性。

EEG 信号由 128 通道 HydroCel Geodesic Sensor Net 和 Net Station 采集软件记录,因此,本实验通过 EEGLAB 中的 Netstation binary simple file 插件导入脑电数据,使用 Filter the data 工具进行 0.1~70 Hz 的带通滤波,采用 Select data 去掉 EEG 中眼电和肌电等无关电极,检查是否有坏导环段。剔除环段并进行插值坏导,最后,使用独立成分分析 ICA 去除 EEG 记录中的各种伪影。

EEG 数据预处理之后,使用 MNE Python 库读取原始数据并创建二维矩阵,通道为列,时间步长为行,提取前 128 个采样点的数据作为一个 EEG 信号片段,对于每一个 EEG 片段选取了 29 个稳定的通道信号作为通道列表,它们分别是电极 [F7、F3、Fz、F4、F8、T7、C3、Cz、C4、T8、P7、P3、Pz、P4、P8、O1、O2、Fpz、F9、FT9、FT10、TP9、TP10、PO9、PO10、Iz、A1、A2、POz]。对于每一个通道使用窗口大小为 1024 的 Hanning 窗口对信号进行加窗处理,然后利用短时傅里叶变换 (Short-Time Fourier Transform, STFT) 将信号转换为频谱数据,计算其频谱幅度,并将其标准化为幅度谱,最后将其绘制为时频图,得到 EEG 数据的时频特征。

2.2 实验环境及参数设置

本文实验基于 Python 3.7.16 和 PyTorch 1.13.1 框架实现,训练和测试在 NVIDIA RTX 3090 (24 GB) GPU 上运行。

基于 MODMA 数据集的所有 EEG 数据,本文采用了不同的分类器对原始数据和增强后的数据进行了大量的实验来验证所提方法的有效性。

首先,对 MODMA 数据集上所有被试的 29 个通道的脑电信号,通过短时傅里叶变换将其转换为时频图,得到抑郁症患者时频特征 696 个,正常对照时频特征 841 个,总共 1537 个样本。将抑郁患者和正常对照的时频特征分别送入扩散模型进行训练,生成新的抑郁和正常的时频特征,进而对训练数据集进行增强。随机抽取 20% 的 EEG 数据用于进行测试,其余的数据用于训练,并分别送入 Vision Transformer(ViT)^[13]、MLP (Multilayer Perceptron) 和 SVM(Support Vector Machine) 不同的分类器进行分类,得到最终的实验结果。

2.3 逐步扩充训练集的实验结果

为了探究不同程度扩充训练数据集对实验结果的影响,本文针对 MODMA 数据集分别生成了不同数量的样本进行分类实验。以原始 EEG 时频特征为基准,实验分别生成了原始训练数据集 0.6、0.8、1、1.2 和 1.5 倍的时频特征样本。将生成的时频特征添加到原始数据集中对其进行扩充增强。然后分别采用 ViT、MLP 和 SVM 3 种不同的模型对其进行分类,实验结果见表 1。

表 1 不同增强程度的分类准确率

Tab.1 The classification accuracy with different levels of augmentation

添加的样本量	准确率/%		
	ViT	MLP	SVM
0	80.91	86.73	69.58
0.6	87.70	88.03	72.49
0.8	88.03	89.64	73.14
1	91.90	90.61	75.08
1.2	87.38	90.29	71.84
1.5	88.75	88.67	70.55

添加的样本数量表示原始训练数据集扩增倍数。由表 1 可以看出,在 3 个不同的分类器上进行抑郁症分类实验,使用增强之后的数据集的准确率普遍比采用原始数据集在平均分类精度上高。当添加的样本量达到原始训练数据集的 1 倍时,在 ViT、MLP 和 SVM-3 个分类器上进行抑郁症分类均达到了最好的效果,其平均分类准确率分别是 91.90%、90.61% 和 75.08%,较原始训练数据集的平均分类准确率分别提高了 10.99%、3.88% 和 5.50%。以上结果均表明采用扩散模型生成的新样本对原始训练数据集进行扩充增强能够有效地提高抑郁症检测的识别效果。

同时,可以看出采用深度神经网络 ViT 和 MLP 进行实验的平均分类准确率比采用传统分类器 SVM 有显著的提高。说明深度神经网络能够从原始数据中学到更加抽象和高级的特征表示;能够更好地捕获数据中的相关信息和结构,从而提高分类的准确度。在样本量较小的时候,采用 MLP 分类器得到最优的分类结果,但随着扩充样本数量的逐渐增大,采用 ViT 相较于 MLP 表现出了更好的分类效果。说明 ViT 可以更加有效地处理大规模数据,可能是因为随着数据量的增大,数据集中存在更加复杂和多样化的模式和结构,ViT 可以通过自注意力机制实现对序列数据的建模,其参数只与序列长度相关,

而不是与数据量大小相关。因此,随着数据量的增大,ViT 的参数数量相对较小,不会过拟合。相比之下,MLP 通常在处理大规模数据时需要更多的参数和更复杂的结构来达到相同的效果,这容易导致过拟合。因此,ViT 更适合在大规模数据集上进行训练,能够表现出更好的抑郁症分类效果。

随着数据量的进一步增大,在 3 个分类器上平均分类准确率均出现了下降。由此可知,在一定的范围内,增加数据量可以提高分类器的准确率,这是因为 EEG 数据的采集长度是有限的,适当的数据扩充倍数可以更好地利用数据中的特征信息。如果扩充倍数太小,可能无法充分学习数据的特征,导致分类效果不佳;而如果扩充倍数太大,可能会使增强后的数据变得难以处理,同样影响分类性能。因此,在数据扩充时需要进行适当的倍数选择,以达到最佳的分类效果。

2.4 消融实验结果

通过上述的实验分析可得,在 1 倍的数据扩充下能够达到最好的分类效果。为了进一步验证所提方法的有效性,分别采用原始扩散模型 DDPM 和本文所提方法卷积注意力扩散模型 CADM 生成原始脑电数据 1 倍的人工样本,然后,分别添加抑郁患者和正常对照的训练数据集,采用不同的分类器,包括 ViT、MLP 和 SVM 等算法对增强后的数据进行分类实验,对比结果见表 2。

表 2 不同模型分类准确率

Tab.2 The classification accuracy of different models

添加的样本量	准确率/%		
	ViT	MLP	SVM
原始样本	80.91	86.73	69.58
DDPM	90.15	89.32	73.79
CADM	91.90	90.61	75.08

通过表 2 可以看出,在 3 个不同的分类器上进行分类实验,增强后的数据普遍比原始数据分类精度更高,说明通过扩散模型能够生成有效的 EEG 数据特征,可以提高神经网络的分类能力,在数据量较少的情况下,对数据进行扩充和增强是非常有意义的。与原始扩散模型 DDPM 相比,本文所提模型 CADM 在抑郁症分类实验上表现出了更好的性能,分别在 ViT、MLP 和 SVM 平均分类准确率上提高了 1.75%、1.29% 和 1.29%。说明通过引入卷积注意力机制可以提升模型对输入特征的表征能力,证明所提方法能够生成更加有效和高质量的脑电数据特征,能够有效地提高 EEG 抑郁症识别的准确率和稳定性。同时,可以看出,针对传统的分类器,ViT 表现出了更好的分类性能,说明深度神经网络能够有效地提取 EEG 数据深层特征,对于区分抑郁症患者和正常人更有帮助。

3 结论(Conclusion)

针对抑郁症检测中脑电数据采集难度大、样本量小的问题,本文提出了一种卷积注意力扩散模型(CADM)方法进行 EEG 数据增强,分别采用了 ViT、MLP 和 SVM 等不同模型进行了分类任务来验证所提模型的有效性。实验结果表明,这 3 种模型均取得了较高的分类准确率,且相较于未经扩散模型增

强的原始数据,分类性能均得到了显著提升。通过引入卷积注意力扩散模型,有效地消除了数据中的噪声和无关信息,突出了与抑郁症相关的生理特征,提高了数据的有效性和分类性能。其中,ViT模型展现出了突出的能力,其在大规模数据集上的学习能力和特征提取能力使得其在抑郁症 EEG 数据分类任务中取得了优异的成绩,达到了最优的平均分类准确率 91.90%,较原始数据集的平均分类准确率提高了 10.99%。以上结果均证明了本文所提模型的有效性和通用性。由于扩散模型采用马尔可夫链,每次采样都需要经过多次迭代和计算,因此,生成效率非常低。未来的研究可以进一步探索如何优化扩散模型的生成效率,结合受试者的脑电数据生成更加高质量的数据,结合更加高效的模型可以进一步提升抑郁症分类性能。

参考文献(References)

- [1] 温敏,张云淑,王素娟,等. 抑郁症患者认知功能的脑电及眼动研究进展[J]. 中国健康心理学杂志,2022,30(8): 1277-1280.
- [2] HE C, LIU J, ZHU Y, et al. Data augmentation for deep neural networks model in EEG classification task: A review [J]. Frontiers in human neuroscience, 2021, 15: 765525.
- [3] PASCHALI M, SIMSON W, ROY A G, et al. Manifold exploring data augmentation with geometric transformations for increased performance and robustness[C]//LNCS. Information Processing in Medical Imaging: 26th International Conference. Berlin: Springer, 2019: 517-529.
- [4] OKAFOR E, SMIT R, SCHOMAKER L, et al. Operational data augmentation in classifying single aerial images of animals[C]//INISTA. 2017 IEEE International Conference on Innovations in Intelligent Systems and Applications. New York: IEEE, 2017: 354-360.
- [5] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial networks [J]. Communications of the ACM, 2020, 63(11): 139-144.
- [6] LUO Y, ZHU L Z, WAN Z Y, et al. Data augmentation for enhancing EEG-based emotion recognition with deep generative models[J]. Journal of neural engineering, 2020, 17(5): 056021.
- [7] FAHIMI F, DOSEN S, ANG K K, et al. Generative adversarial networks-based data augmentation for brain-computer interface [J]. IEEE Transactions on neural networks and learning systems, 2021, 32(9): 4039-4051.
- [8] DHARIWAL P, NICHOL A. Diffusion models beat GANs on image synthesis [J]. Advances in neural information processing systems, 2021, 34: 8780-8794.
- [9] DUAN Y, ZHOU J, WANG Z, et al. Domain-specific denoising diffusion probabilistic models for brain dynamics [EB/OL]. (2023-05-15) [2024-04-23]. <https://arxiv.org/abs/2305.04200>.
- [10] TORMA S, SZEGLETES L. Brain signal generation and data augmentation with a single-step diffusion probabilistic model [EB/OL]. (2023-02-14) [2024-04-23]. <https://openreview.net/forum?id=woOQ5Hb1oOF>.
- [11] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models [J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
- [12] CAI H, YUAN Z, GAO Y, et al. A multi-modal open dataset for mental-disorder analysis [J]. Scientific data, 2022, 9(1): 178.
- [13] QAYYUM A, RAZZAK I, TANVEER M, et al. High-density electroencephalography and speech signal based deep framework for clinical depression diagnosis [J]. IEEE/ACM transactions on computational biology and bioinformatics, 2023, 20(4): 2587-2597.

作者简介:

汪子凯(2000-),男(汉族),达州,硕士生。研究领域:脑电信号处理与情感计算,深度学习与数据增强。

陈景霞(1979-),女(汉族),石河子,博士,教授。研究领域:深度学习,脑电等生物信号处理,多模态情感计算,数据挖掘。

贾晓雯(1999-),女(汉族),忻州,硕士生。研究领域:生理信号处理,多模态抑郁症检测。

赵晨(1998-),男(汉族),西安,硕士生。研究领域:深度学习,扩散模型,数据增强,图像分割。

(上接第 42 页)

- [13] BANDI P, GEESINK O, MANSON Q, et al. From detection of individual metastases to classification of lymph node status at the patient level: The camelyon17 challenge [J]. IEEE transactions on medical imaging, 2019, 38(2): 550-560.
- [14] KARTHIK M, DANE S. Aptos 2019 blindness detection [EB/OL]. (2020-12-11) [2024-09-26]. <https://www.kaggle.com/c/aptos2019-blindness-detection>.

作者简介:

王瑞琦(1999-),女(汉族),吕梁,硕士生。研究领域:联邦学习,图像处理。

李峰(1968-),男(汉族),镇江,副教授,博士。研究领域:图像处理,嵌入式计算。

范佳屹(1999-),男(汉族),苏州,硕士生。研究领域:深度学习,图像处理。