

基于信息最大化生成对抗网络的运动想象 脑电信号数据增强

肖楠¹ 李明爱^{1,2,3}

摘要 目的 运动想象脑电信号 (motor imagery electroencephalography, MI-EEG) 是脑机接口 (brain-computer interfaces, BCI) 中的一种经典范式,而数据量不足问题制约着它的研究与应用。随着深度学习的发展,生成对抗网络 (generative adversarial networks, GAN) 成为一种有潜力的数据增强方法,但其却面临着生成数据特征难以自动控制和数据多样性不佳的困难。为此,本文提出了一种基于信息最大化生成对抗网络 (information maximization GAN, InfoGAN) 的 MI-EEG 数据增强方法。**方法** 首先,针对 MI-EEG 的多导联时间序列特点,设计基于深度卷积的 InfoGAN (deep convolution information maximizing GAN, DCIMGAN)。然后,基于 BCI Competition IV 2a/2b 数据集,使用 3 种经典深度学习模型 (EEGNet、FBMSNet 和 MI-BMInet) 在有无生成数据参与训练的条件下进行性能对比分析,以评估生成数据对分类模型训练的影响。最后,以 EEGNet 作为基础分类模型,进一步对比了本文提出的增强方法与现有的多种数据增强策略 (包括随机噪声添加、时间偏移、幅值缩放和信号翻转) 在分类性能上的差异,探讨不同数据增强方法的优劣性。**结果** DCIMGAN 由一个生成器 G 及两个鉴别器 D 和 Q 组成。G 的输入为随机噪声和潜在变量,输出生成数据;D 和 Q 的输入为真实数据和生成数据,分别用于判别样本真假和估计潜在变量的值。通过在训练过程中引入生成数据与潜在变量之间的互信息损失,实现对生成器的有效控制。增加 DCIMGAN 生成数据可使 3 种模型对于 BCI Competition IV 2a/2b 数据集的分类准确率分别提升 3.51%/7.00%、2.55%/2.10% 和 3.92%/9.26%。**结论** DCIMGAN 能够自动控制生成数据特征,获得与真实数据相似度高的 MI-EEG 数据,相对常用数据增强方法更有效提升分类模型性能。

关键词 运动想象信号;生成对抗网络;深度卷积神经网络;数据增强

DOI: 10.3969/j.issn.1002-3208.2025.05.002.

中图分类号 R318.04 **文献标志码** A **文章编号** 1002-3208(2025)05-0449-08

本文著录格式 肖楠,李明爱. 基于信息最大化生成对抗网络的运动想象脑电信号数据增强[J]. 北京生物医学工程, 2025, 44(5): 449-456. XIAO Nan, LI Ming' ai. Data augmentation for motor imagery signals based on information maximization generative adversarial networks [J]. Beijing Biomedical Engineering, 2025, 44(5): 449-456.

Data augmentation for motor imagery signals based on information maximization generative adversarial networks

XIAO Nan¹, LI Ming' ai^{1,2,3}

1 School of Information Science And Technology, Beijing University of Technology, Beijing 100124;

2 Beijing Key Laboratory of Computational Intelligence and Intelligent System, Beijing 100124;

3 Engineering Research Center of Digital Community, Ministry of Education, Beijing 100124

Corresponding author: LI Ming' ai (E-mail: limingai@bjut.edu.cn)

[Abstract] **Objective** Motor imagery electroencephalography (MI-EEG) is a classic paradigm in brain-computer interfaces, but the limited data available hinders its research and application. With the development of deep learning, generative adversarial networks (GANs) have emerged as a potential data augmentation method,

though they face challenges in controlling the generated data features and ensuring data diversity. To address these issues, this paper proposes a motor imagery (MI) EEG data augmentation method based on an information maximization GAN (InfoGAN). **Methods** Firstly, based on the multi-lead time series characteristics of MI-EEG, an InfoGAN (deep convolution information maximizing GAN, DCIMGAN) was designed. Then, based on the BCI Competition IV 2a/2b datasets, three classic deep learning models (EEGNet, FBMSNet, and MI-BMI-net) were used to conduct a comparative analysis of performance with and without generated data in training, in order to evaluate the impact of generated data on the training of classification models. Finally, using EEGNet as the basic classification model, a further comparison was made between the proposed enhancement method and various existing data augmentation strategies (including random noise addition, time shifting, amplitude scaling, and signal flipping) in terms of classification performance, to explore the advantages and disadvantages of different data augmentation methods. **Results** DCIMGAN consisted of a generator (G) and two discriminators (D and Q). G took random noise and latent variables as inputs to generate data, while D and Q differentiate between real and generated samples and estimate the values of latent variables, respectively. Mutual information loss between the generated data and latent variables was introduced during training to effectively control the generator. The inclusion of DCIMGAN-generated data improved the average classification accuracy of three classic deep learning models (EEGNet, FBMSNet, and MI-BMI-net) by 3.51%/7.00%, 2.55%/2.10%, and 3.92%/9.26%, respectively. **Conclusions** DCIMGAN can automatically control the features of generated data, producing MI-EEG signals with high similarity to real data, and is more effective than commonly used data augmentation methods in improving classification model performance.

【Keywords】 motor imagery signals; generative adversarial networks; deep convolutional neural networks; data augmentation

0 引言

脑机接口 (brain-computer interface, BCI) 通过采集大脑电信号并解码指令控制外部设备^[1]。脑电图 (electroencephalography, EEG) 因其非侵入性、安全性和记录皮质电活动的优势, 被广泛应用于 BCI 研究^[2]。然而, 构建高效 BCI 系统需要大量高质量的 EEG 数据, 但受限于受试者不适、疲劳及操作复杂性, EEG 数据难以充分获取^[3]。因此, 生成高质量的人工 EEG 数据成为解决这一问题的潜在方案^[4]。

传统的数据增强方法, 如噪声添加、滑窗、几何变换和分割重组等^[5-8], 在一定程度上提升了数据多样性, 但对特征分布改善有限, 甚至可能引入不利偏差。随着深度学习的快速发展, 数据生成方法取得了显著进展, 特别是生成对抗网络 (generative

adversarial network, GAN)^[9]的提出, 有效缓解了数据不足的问题。已有研究将 GAN 应用于 EEG 数据增强, 结合特定神经网络结构生成数据, 如长短期记忆 (long short-term memory, LSTM)、递归神经网络 (recurrent neural network, RNN) 和卷积神经网络 (convolutional neural network, CNN) 等模型^[10]。特别是基于 CNN 的 GAN 网络生成的数据在 EEG 分类准确性提升方面表现尤为显著^[11]。Khoyani 等^[12]提出了一个深度卷积 GAN (deep convolutional GAN, DCGAN), 使用多层卷积神经网络在生成运动想象 (motor imagery, MI) 数据方面取得良好效果; Fahimi 等^[13]则更进一步, 设计了条件深度卷积 GAN (conditional DCGAN, cDCGAN), 通过整合条件信息进一步提升了生成数据的质量。另一方面, 沃瑟斯坦 GAN (Wasserstein GAN, WGAN) 优化了 GAN 框架, 通过沃瑟斯坦距离改进了模式崩溃问题的解决, 提升了模型稳定性^[14], Kay 等^[15]提出的 EEG-GAN 就是基于此实现的。Li 等^[16]则更进一步, 提出了条件 WGAN (cWGAN), 将条件信息融入 WGAN 框架, 使得生成的数据能够基于特定条件更精准地匹配目标分布。条件 GAN 可以根据给定的条件向量生成

基金项目: 国家自然科学基金 (62173010) 资助

作者单位: 1 北京工业大学信息科学技术学院 (北京 100124)

2 计算智能与智能系统北京市重点实验室 (北京 100124)

3 数字社区教育部工程研究中心 (北京 100124)

通信作者: 李明爱。E-mail: limingai@bjut.edu.cn

特定样本,但这一过程依赖于人工设定的条件向量,限制了生成模型的灵活性。在图像生成领域,Chen 等^[17]提出了信息最大化生成对抗网络 (information maximizing GAN, InfoGAN),该方法能够自动学习潜在变量的结构,而且通过最大化生成样本与潜在变量之间的互信息,使得生成样本的特定特征能够有效解码和控制,增强了数据的多样性和质量。

受 InfoGAN 启发,本文针对 MI-EEG 的多导联时间序列特点,提出一种基于深度卷积的数据增强方法,即深度卷积信息最大化 GAN (deep convolution information maximizing GAN, DCMIGAN),以自动控制生成数据特征,提升数据质量,进而缓解 MI 信号数据不足问题。

1 方法

1.1 DCMIGAN 模型整体架构

为了有效应对 MI-EEG 信号中多导联时间序列的复杂性与多样性,本文提出了 DCMIGAN 模型,它由生成器 G 和两个鉴别器 D 与 Q 组成。 G 接收随机噪声 z 和潜在变量 c 作为输入,允许生成过程不仅仅由噪声驱动,还能通过潜在变量对生成数据的特征进行控制,输出生成数据 $G(z, c)$ 。鉴别器 D 和 Q 以真实数据 $x \in \mathbb{R}^{C \times T}$ (C 表示电极数, T 表示采样点数) 和生成数据 $G(z, c)$ 为输入,它们共享网络参数,仅在最后一层通过不同的全连接层分别输出真假判断和潜在变量的估计。DCMIGAN 基本架构如图 1 所示。




图 1 DCMIGAN 的基本结构
Figure 1 The basic structure of DCMIGAN

1.2 生成器 G 的网络结构

G 由一个全连接层 (fully connected layer, FC)、三个连续的转置卷积层 (transpose convolution layer, TransConv) 和一个卷积层 (convolutional layer, Conv) 组成。在每个转置卷积层后,接入 LeakyReLU 激活函数并进行批归一化 (batch normalization, BN) 操

作,以稳定梯度并有效避免梯度消失或爆炸,从而加速训练过程并促进生成器的快速收敛。 G 的具体网络结构如图 2 所示,详细的网络参数配置列于表 1。




图 2 G 的网络结构
Figure 2 The network structure of G

表 1 生成器的网络参数设置

Table 1 Generator network parameter settings			
网络层	参数	激活函数	输出
线性全连接层	1 250	LeakyReLU	$B \times 1\ 250$
批归一化层			$B \times 1\ 250$
变形层			$B \times 10 \times 125$
转置卷积层	(10, 20, 4, 2, 1)	LeakyReLU	$B \times 20 \times 250$
批归一化层			$B \times 20 \times 250$
转置卷积层	(20, 40, 4, 2, 1)	LeakyReLU	$B \times 40 \times 500$
批归一化层			$B \times 40 \times 500$
转置卷积层	(40, 80, 4, 2, 1)	LeakyReLU	$B \times 80 \times 1\ 000$
批归一化层			$B \times 80 \times 1\ 000$
卷积层	(80, 22, 1, 1, 0)	LeakyReLU	$B \times 22 \times 1\ 000$
批归一化层			$B \times 22 \times 1\ 000$

1.3 鉴别器 D 、 Q 的网络结构

D 和 Q 的核心结构由 4 个连续卷积层组成,每层后接 leakyReLU 激活函数和批归一化操作。两者的差异在于: D 在卷积模块后仅包含一个全连接层,通过 sigmoid 激活函数进行真假数据分类;而 Q 包含两个全连接层,用于输出潜在变量 c 。鉴别器的网络结构如图 3 所示,具体的网络参数配置见表 2,其中 B 表示批量大小 (batch size), C 表示电极数。

1.4 DCMIGAN 训练

网络训练过程分为以下几个步骤:首先, G 接收随机噪声 z 和潜在变量 c 作为输入,并生成数据 $G(z, c)$;然后将相同数量的真实样本 x 和生成样本

$G(z, c)$ 输入到 D 和 Q , 计算并优化各自的损失。

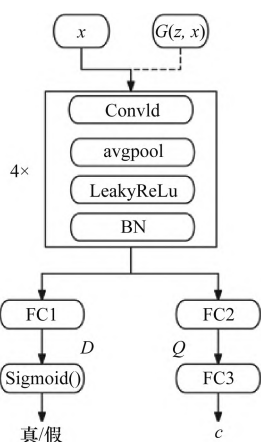


图 3 D 、 Q 网络结构

Figure 3 The structure of D and Q

表 2 鉴别器的网络参数设置

Table 2 Discriminator network parameter settings

网络层	参数	激活函数	输出
卷积层	(80, C, 1, 1, 0)	LeakyReLU	$B \times 80 \times 1\ 000$
批归一化层			$B \times 80 \times 1\ 000$
卷积层	(80, 40, 4, 2, 1)	LeakyReLU	$B \times 40 \times 500$
批归一化层			$B \times 40 \times 500$
卷积层	(40, 20, 4, 2, 1)	LeakyReLU	$B \times 20 \times 250$
批归一化层			$B \times 20 \times 250$
卷积层	(20, 10, 4, 2, 1)	LeakyReLU	$B \times 10 \times 125$
批归一化层			$B \times 10 \times 125$
展开层			$B \times 1250$
(D)			
线性全连接层	1	Sigmoid	$B \times 1$
(Q)			
线性全连接层	100	LeakyReLU	$B \times 100$
线性全连接层	10		$B \times 10$

D 目标是最大化真实样本和生成样本的区分度, 以便有效判断输入样本的真实性。 D 的损失函数为:

$$L_D = -\mathbb{E}_{x \sim p_{data}} [\log D(x)] - \mathbb{E}_{z \sim p_z} [\log 1 - D(G(z, c))]$$

式中: $D(x)$ 为判别器对真实数据的判断; $D(G(z, c))$ 为判别器对生成数据的判断。

Q 的任务是最大化生成数据 $G(z, c)$ 与潜在变量 c 之间的互信息, 从而确保生成数据的潜在特征能够被有效解码并加以控制。 Q 的损失函数为:

$$L_Q = L_{MI} = -\mathbb{E}_{z \sim p_z, c \sim p_c} [\log Q(c | G(z, c))]$$

然后, 开始更新 G 。 G 的损失包含两个部分: 对抗损失 L_G^{adv} 和互信息损失 L_{MI} 。 G 的损失函数为:

$$L_G = L_G^{adv} + \lambda L_{MI}$$

其中, 对抗损失通过使生成样本尽可能接近真实样本, 提升生成数据的质量; 互信息损失则通过最大化生成数据与潜在变量 c 之间的互信息, 提高生成数据的可控性与多样性。参数 λ 则是用于平衡这两类损失, 经过实验本文设置为 4。具体地, 对抗损失可以表示为:

$$L_G^{adv} = -\mathbb{E}_{z \sim p_z, c \sim p_c} [\log D(G(z, c))]$$

训练过程中, 采用交替更新的策略, 即先更新 D 和 Q 的参数, 再更新 G 的参数。这个过程持续进行, 直到网络训练收敛, G 能够产生与真实样本相似的高质量数据, 并且潜在变量能够有效地控制生成数据的特征。

2 实验与结果分析

2.1 数据集

本文使用 BCI Competition IV 2a 和 2b 数据集进行实验。2a 数据集包含 9 名健康受试者在 250 Hz 采样率下, 使用 22 个电极记录的 EEG 信号, 频段为 0.5~100 Hz。受试者执行 4 种 MI 任务(左手、右手、双脚、舌头), 每个受试者分别完成两组实验(session1 和 session2), 每次 MI 持续 4 s。本研究仅使用 session1 数据训练生成器和判别器。2b 数据集也包含 9 名受试者, 使用 3 个电极记录左手和右手的 MI 信号, 其他设置与 2a 相同。每个受试者完成 5 组实验(session1~session5), 本研究仅使用前 3 组数据用于训练。2a 数据集电极数为 22 ($C=22$), 2b 数据集为 3 ($C=3$), 每次试验有 1 000 个采样点 ($T=1\ 000$)。

2.2 实验细节

DCMIGAN 的训练和测试是在 Geforce 3080Ti GPU 和 Windows 10 系统下, 使用 Python 语言, 基于 pytorch 框架完成的。优化器选用的是 Adam, 批量大小设置为 72, 训练轮次(epoch number)为 50 000。为确保数据的稳定性和一致性, 对数据做了归一化及删除工频干扰处理。

2.3 实验结果与分析

2.3.1 时域分析

为了评估生成信号在时域上的表现, 以 2a 数据集受试者 A01 为例, 对比了相同批量大小下真实信号与生成信号在多个通道上的平均值和标准差, 如

图4所示。其中,绿色曲线代表真实信号,红色曲线代表生成信号,阴影部分表示标准差范围。可以看出,生成信号在4类MI任务中的统计特性与真实信号高度一致,且在时域上能够较好地拟合真实信号的波动模式,表现出较高的一致性。

2.3.2 时频分析

为了进一步展示生成信号的质量,仍以2a数据集受试者A01为例,采用连续小波变换对真实信号和生成信号进行时频分析,得到的能量分布如图5所示。从图中可以观察到,生成信号与真实信号在0~3 s的时间窗口内和在0~30 Hz频段内的能量分布表现出了较高的一致性。特别是在高能量区域(即颜色较深的部分),生成信号能够有效地拟合真实信号的时频特性,表明生成信号在时频域上的特性得到了较好的保留。该结果表明,本文方法能够较好地再现信号的时频特征,进一步证明了生成信号的真实性和可靠性。

2.3.3 t-SNE 可视化分析

为进一步验证生成信号在特征空间中的表现,仍以2a数据集中A01受试者为例,使用t-SNE方法对真实数据(训练集)和生成样本(数量与真实数据相等)进行了二维映射,如图6所示。从图中可以

看到,生成信号与真实信号在t-SNE空间中的分布高度重叠,表明生成信号成功地捕捉到了真实信号的特征结构。这一结果表明,生成的EEG信号在高维特征空间中与真实信号具有相似的分布,从而验证了生成模型在保留数据结构方面的有效性。

3 讨论

为了全面评估生成数据的质量,本文不仅通过直观的可视化结果对生成数据的特性进行初步分析,还通过定量实验进一步验证其有效性,并与其他方法进行对比。具体而言,首先,本文选择3种经典的MI-EEG分类模型在有生成数据参与训练的条件下进行性能对比分析,以评估生成数据对分类模型训练的影响;其次,以EEGNet作为基础分类模型,进一步对比本文提出的增强方法与现有的多种数据增强策略(包括随机噪声添加、时间偏移、幅值缩放和信号翻转)在分类性能上的差异,探讨了不同数据增强方法的优劣性。

3.1 DCMIGAN 对分类性能的提升分析

为验证生成数据对分类性能的具体影响,本文选取了3种经典的MI-EEG分类模型EEGNet^[18]、FBMSNet^[19]和MI-BMInet^[20],并在有无生成数据参

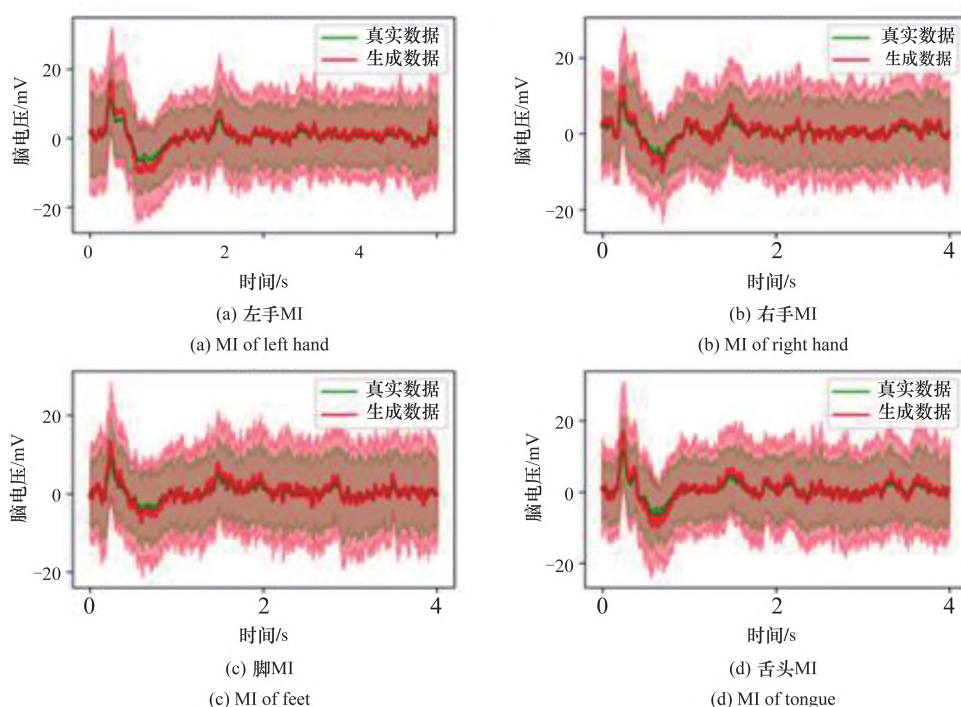


图4 真实信号和生成信号在时域上分布对比

Figure 4 Comparison of time-domain distributions between real and generated signals




图 5 真实信号和生成信号能量分布图对比

Figure 5 Comparison of energy distribution between real and generated signals




图 6 真实样本和生成样本的 T-SNE 嵌入图

Figure 6 T-SNE embedding of real and generated samples

与训练的条件下进行实验。所有实验均基于 2a 和 2b 数据集,并严格控制生成数据量与真实数据量一致,以确保对比结果的公平性。实验结果如图 7 所示,添加生成数据后,分类模型在两种数据集上的性能均显著提升。具体而言,在 2a 数据集上 3 个分类模型的准确率分别提升了 3.51%、2.55%、3.92%,在 2b 数据集上分别提升了 7.00%、2.10%、9.26%。这一结果表明,生成数据有效弥补了原始数据的不足,显著提升了模型的分类准确性。

3.2 与其他方法的对比

本文进一步以 EEGNet 为基准模型对不同数据增强方法(包括随机噪声添加、时间偏移、幅度缩放和信号翻转)以及 DCMIGAN 生成的数据进行分类性能的对比实验。实验基于 BCI Competition IV 2a 和 2b 数据集,生成数据量与真实数据量保持一致,以确保对比的公平性。实验结果表明,DCMIGAN 生成的数据在绝大多数受试者上表现优于传统数据增强方法,具体实验结果见表 3。统计数据显示,DCMIGAN 生成数据的平均分类准确率在 2a 数据集上为 75.23%,在 2b 数据集上为 81.44%,均显著高于无数据增强及其他常见数据增强方法的结果。

4 结论

本文提出了一种基于信息最大化生成对抗网络的 MI-EEG 数据增强方法 DCMIGAN,通过引入潜在变量有效控制生成数据的特征,提升了生成数据的质量和可控性。实验结果表明,DCMIGAN 生成的数据在 2a 和 2b 数据集上显著提高了多个模型的性能,优于传统数据增强方法。该方法在不同分类模型中的适应性展示了其在 BCI 系统中的潜力,尤其在低质量或数据不足的场景中具有较强的实际

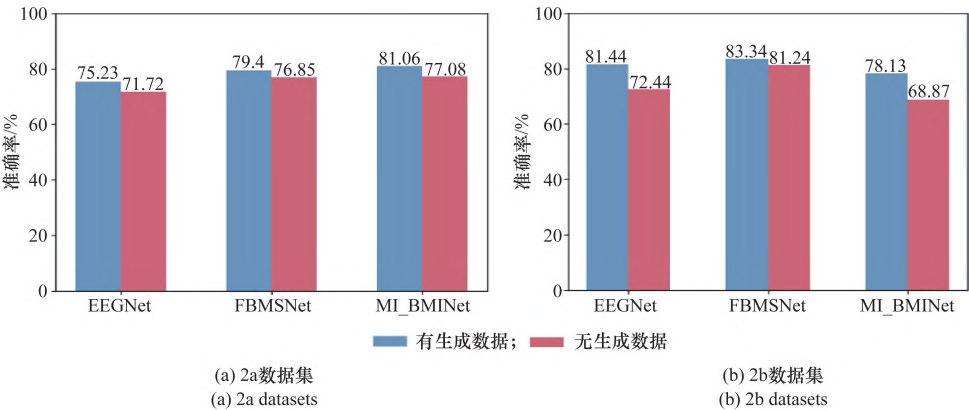


图 7 不同数据集与模型下生成数据对分类性能的影响

Figure 7 The impact of generated data on classification performance across different datasets and models

表 3 基于 EEGNet 不同数据增强方法的性能对比

Table 3 Performance comparison of different data augmentation methods based on EEGNet

数据集	受试者	数据增强方法					
		无	噪声添加	时间偏移	幅度缩放	信号翻转	DCMI GAN
2a	A01	81.25%	80.56%	78.13%	80.21%	77.78%	82.99%
	A02	59.03%	62.85%	59.03%	60.07%	62.15%	63.54%
	A03	87.15%	89.58%	87.85%	86.81%	88.19%	87.50%
	A04	61.11%	68.75%	68.06%	63.19%	69.79%	65.97%
	A05	68.75%	70.49%	72.22%	71.88%	71.18%	70.49%
	A06	60.76%	53.47%	58.68%	61.46%	65.28%	62.15%
	A07	69.10%	69.10%	69.79%	67.01%	70.14%	87.85%
	A08	74.65%	75.69%	79.17%	82.29%	77.08%	77.08%
	A09	83.68%	77.08%	80.90%	80.56%	78.82%	79.51%
	平均	71.72%	71.95%	72.65%	72.61%	73.38%	75.23%
2b	B01	52.81%	70.63%	69.69%	71.56%	72.81%	70.31%
	B02	52.86%	62.14%	61.79%	61.43%	60.71%	63.57%
	B03	71.25%	74.38%	74.69%	78.13%	77.19%	74.38%
	B04	93.75%	96.88%	96.25%	97.19%	96.88%	97.19%
	B05	78.44%	88.13%	89.38%	92.50%	80.00%	87.81%
	B06	71.56%	80.63%	72.50%	63.75%	70.31%	83.44%
	B07	74.06%	83.75%	83.13%	86.56%	83.75%	85.00%
	B08	81.25%	89.38%	90.00%	90.00%	90.63%	89.06%
	B09	75.94%	79.69%	83.13%	83.44%	81.56%	82.19%
	平均	72.44%	80.62%	80.06%	80.51%	79.32%	81.44%

注:最优性能的数据增强方法获得的数据使用加粗表示。

应用价值。未来研究可进一步探讨该方法在多种 BCI 任务中的应用,并提升生成模型的复杂度以进一步优化分类精度。

参考文献

[1] Ramadan RA, Vasilakos AV. Brain computer interface: control signals review[J]. Neurocomputing, 2016, 223(FEB.5): 26-44.

[2] Fouad MM, Amin KM, El-Bendary N, et al. Brain computer interface; a review[C]// Nirma University. In Proceedings of the 2015 5th Nirma University International Conference on Engineering (NUiCONE). Ahmedabad, India; IEEE, 2015; 1-6.

[3] Lotte F, Congedo M, Lécuyer A, et al. A review of classification algorithms for EEG-based brain-computer interfaces[J]. Neural Engineering, 2007, 4(2): R1-R13.

[4] Fahimi F, Dosen S, Ang KK, et al. Generative adversarial networks-based data augmentation for brain-computer interface[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(9): 4032-4051.


[5] Li Y, Zhang XR, Zhang B, et al. A channel-projection mixed-scale convolutional neural network for motor imagery EEG decoding[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2019, 27(6): 1170-1180.

[6] Majidov I, Whangbo T. Efficient classification of motor imagery electroencephalography signals using deep learning methods[J]. Sensors, 2019, 19(7): 1736.

[7] Shovon TH, Al Nazi Z, Dash S, et al. Classification of motor imagery EEG signals with multi-input convolutional neural network by augmenting STFT[C]// Dhaka University. In Proceedings of the 2019 5th International Conference on Advances in Electrical Engineering (ICAEE). Dhaka, Bangladesh; IEEE, 2019; 398-403.

[8] Dai GH, Zhou J, Huang J, et al. HS-CNN: A CNN with hybrid convolution scale for EEG motor imagery classification[J].

- Neural Engineering, 2020, 17(1):016025.
- [9] Goodfellow IJ. Generative adversarial networks [J]. Communications of the ACM, 2014, 63(11):139–144.
- [10] Wang JS, Mu W, Wang AP, et al. Generative adversarial networks for electroencephalogram signal analysis; a mini review [C]// Korea University, In Proceedings of the 2023 11th International Winter Conference on Brain-Computer Interface (BCI). Gangwon, Korea: IEEE, 2023:1–6.
- [11] Mishra S, Mahmudi O, Jalali A. Motor imagery signal classification using adversarial learning; a systematic literature review [J]. IEEE Access, 2024, 12:91053–91074.
- [12] Khoyani A, Kaur H, Amini M, et al. Motor imagery brain activity recognition through data augmentation using DC-GANs and musigma [C]// IEEE Sensors Council. In Proceedings of the 2022 IEEE Sensors. Dallas, TX, USA: IEEE, 2022:1–4.
- [13] Fahimi F, Dosen S, Ang KK, et al. Generative adversarial networks-based data augmentation for brain-computer interface [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(9):4039–4051.
- [14] Li LL, Cao GZ, Liang HJ, et al. EEG generation of virtual channels using an improved wasserstein generative adversarial networks [C]// Harbin Institute of Technology. In Proceedings of the International Conference on Intelligent Robotics and Applications. Harbin, China: Springer, Cham, 2022:386–399.
- [15] Kay GH, Robin TS, Tonio Ball et al. EEG-GAN: generative adversarial networks for electroencephalographic (EEG) brain signals [J]. arXiv:1806.01875, 2018.
- [16] Li Z, Yu Y. Improving EEG-based motor imagery classification with conditional Wasserstein GAN [C]// Shanghai Advanced Research Institute, Chinese Academy of Sciences. In Proceedings of the 2020 International Conference on Image, Video Processing and Artificial Intelligence. Shanghai: SPIE, 2020:437–443.
- [17] Chen X, Duan Y, Houthoof R, et al. InfoGAN: Interpretable representation learning by information maximizing generative adversarial nets [J]. arXiv:1606.03657, 2016.
- [18] Lawhern VJ, Solon AJ, Waytowich NR, et al. EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces [J]. Neural Engineering, 2018, 15(5):056013.
- [19] Liu K, Yang MZ, Yu ZL, et al. FBMSNet: A filter-bank multi-scale convolutional neural network for EEG-based motor imagery decoding [J]. IEEE Transactions on Biomedical Engineering, 2023, 70(2):436–445.
- [20] Wang XY, Hersche M, Magno M, et al. MI-BMInet: An efficient convolutional neural network for motor imagery brain-machine interfaces with EEG channel selection [J]. IEEE Sensors Journal, 2024, 24(6):8835–8847
- (2024–12–06 收稿, 2025–04–23 修回)



(上接第 448 页)

- [12] Zhou XH, Bian GB, Xie XL, et al. Qualitative and quantitative assessment of technical skills in percutaneous coronary intervention; *In vivo* porcine studies [J]. IEEE Transactions on Biomedical Engineering, 2019, 67(2):353–364.
- [13] Chen DD, Liang SC, Li ZF, et al. A Mock circulation loop for *in vitro* hemodynamic evaluation of aorta: application in aortic dissection [J]. Journal of Endovascular Therapy, 2022, 29(1):132–142.
- [14] 李世龙, 梁世超, 袁盼盼, 等. 基于体外仿生循环实验的 B 型夹层腔间压力功能评估 [J]. 北京生物医学工程, 2023, 42(5):475–482.
- Li SL, Liang SC, Yuan PP, et al. Functional evaluation of luminal pressure in type B aortic dissection based on mock circulation loop [J]. Beijing Biomedical Engineering, 2023, 42(5):475–482.
- [15] Horeman T, Dankelman J, Jansen FW, et al. Assessment of laparoscopic skills based on force and motion parameters [J]. IEEE Transactions on Biomedical Engineering, 2013, 61(3):805–813.
- [16] Anh NX, Nataraja RM, Chauhan S. Towards near real-time assessment of surgical skills: A comparison of feature extraction techniques [J]. Computer Methods and Programs in Biomedicine, 2020, 187:105234.
- [17] Horeman T, Dankelman J, Jansen FW, et al. Assessment of laparoscopic skills based on force and motion parameters [J]. IEEE Transactions on Biomedical Engineering, 2013, 61(3):805–813.
- [18] Tashiro Y, Miura H, Nakanishi Y, et al. Evaluation of skills in arthroscopic training based on trajectory and force data [J]. Clinical Orthopaedics and Related Research, 2009, 467:546–552.
- [19] Guo SX, Cui JX, Zhao Y, et al. Machine learning-based operation skills assessment with vascular difficulty index for vascular intervention surgery [J]. Medical & Biological Engineering & Computing, 2020, 58(8):1707–1721.
- [20] Rolls A, Riga C, Bicknell C, et al. A pilot study of video-motion analysis in endovascular surgery: development of real-time discriminatory skill metrics [J]. European Journal of Vascular and Endovascular Surgery, 2013, 45(5):509–515.
- (2024–03–24 收稿, 2024–06–02 修回)